ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHAI PHÁ DỮ LIỆU DOANH NGHIỆP

KỊCH BẢN THỰC NGHIỆM

DỰ ĐOÁN LOẠI HỌC VIÊN DỰA TRÊN DỮ LIỆU HÀNH VI HỌC TẬP SỬ DỤNG WES - 3 NHÃN

GVHD: ThS. Nguyễn Thị Anh Thư

Lớp: DS317.Q21.VB2

Nhóm 3

Họ và tên	**MSSV**
Trần Thị Minh Hương	24540011
Bùi Hoàng Khánh Linh	24540015
Nguyễn Thanh Sơn	24540022
Huỳnh Ngọc Tài	24540023
Lê Quốc Thái	24540024

ꕥ Tp. Hồ Chí Minh, 05/2026 ꕥ

LỜI CẢM ƠN

Chúng em xin chân thành cảm ơn cô giáo, ThS. Nguyễn Thị Anh Thư, người đã định hướng, giúp đỡ, trực tiếp hướng dẫn và tận tình chỉ bảo chúng em trong suốt quá trình nghiên cứu, xây dựng và hoàn đồ án này.

Chúng em cũng xin được cảm ơn tới gia đình, những người thân và bạn bè thường xuyên quan tâm, động viên, chia sẻ kinh nghiệm, cung cấp các tài liệu hữu ích trong thời gian học tập, nghiên cứu cũng như trong suốt quá trình thực hiện đồ án.

TP. HCM, ngày 6 tháng 5 năm 2026

ĐÁNH GIÁ CỦA GIẢNG VIÊN HƯỚNG DẪN

……

……

……

MỤC LỤC

1. GIỚI THIỆU BÀI TOÁN 5
2. PHẠM VI VÀ MỤC TIÊU NGHIÊN CỨU 6
2.1 Phạm vi nghiên cứu: 6
2.2 Mục tiêu nghiên cứu: 6
3. MỤC TIÊU THỰC NGHIỆM 7
4. MÔI TRƯỜNG THỰC NGHIỆM 7
5. ĐƠN VỊ PHÂN TÍCH VÀ PHẠM VI DỰ BÁO 7
6. CHIẾN LƯỢC GÁN NHÃN 8
7. QUY TRÌNH THỰC NGHIỆM 8
7.1. Giai đoạn 1: Định hình và trích xuất đặc trưng Time-Series 8
7.2. Giai đoạn 2: Khởi tạo nhãn chuẩn (Ground Truth) bằng Weighted Engagement Score (WES) 9
7.3. Giai đoạn 3: Phân chia tập dữ liệu và Xử lý mất cân bằng (SMOTE) 10
7.4. Giai đoạn 4: Huấn luyện và tối ưu mô hình (Supervised Learning) 11
7.5. Giai đoạn 5: Hệ thống tiêu chuẩn đánh giá (Evaluation Metrics) 12
7.6. Giai đoạn 6: Khả năng giải thích mô hình: Model Interpretability 14

1. GIỚI THIỆU BÀI TOÁN

Sự phát triển của các nền tảng học trực tuyến mở đại trà (MOOC) mang lại cơ hội tiếp cận giáo dục quy mô lớn nhưng đồng thời đối mặt với thách thức lớn: tỷ lệ bỏ học (dropout rate) cao do thiếu vắng sự tương tác và giám sát trực tiếp. Để giải quyết vấn đề này, việc xây dựng một hệ thống cảnh báo sớm dựa trên dữ liệu là vô cùng cấp thiết.

Bài toán cốt lõi trong khai phá dữ liệu giáo dục (Educational Data Mining - EDM) là việc định nghĩa và đo lường mức độ tương tác (engagement) của sinh viên thường mang tính chủ quan và tĩnh. Đề tài này giải quyết bài toán đó bằng cách đề xuất một kiến trúc **Hybrid Machine Learning**. Thay vì dựa vào các ngưỡng điểm cố định, hệ thống khai thác chuỗi log thời gian thực, sử dung phương pháp định lượng để khám phá sự phân bố dự liệu của các mẫu hành vi tự nhiên (tạo Ground Truth), sau đó sử dụng các mô hình học có giám sát tiến tiến để phân lớp và dự báo sớm nguy cơ mất động lực học tập của sinh viên.

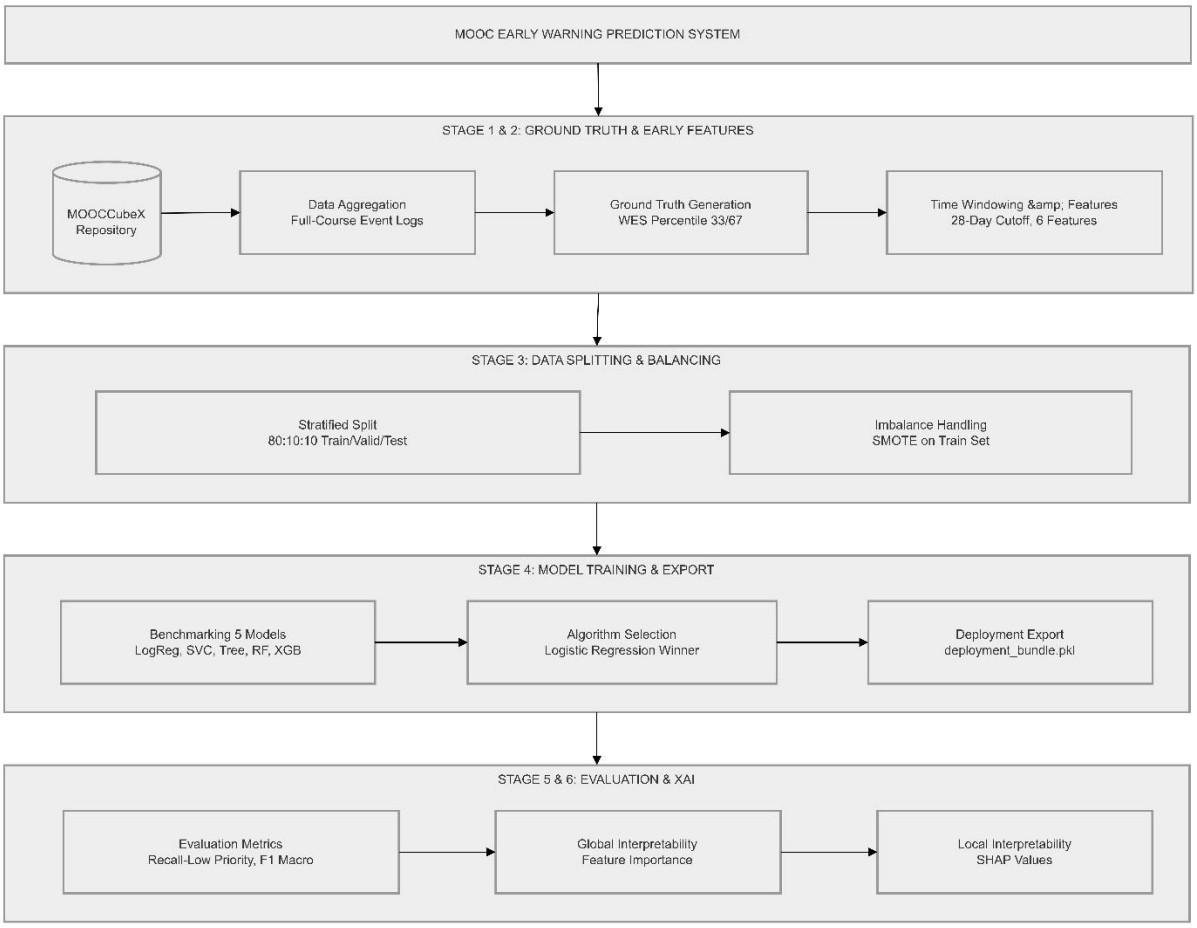

2. PHẠM VI VÀ MỤC TIÊU NGHIÊN CỨU

2.1 Phạm vi nghiên cứu:

- Dữ liệu: Hệ sinh thái MOOCCubeX, bao gồm 5 nguồn dữ liệu dị thể (user, user-video, user-problem, comment, reply). Dữ liệu được tinh gọn thông qua quá trình tiền xử lý, tập trung phân tích tập mẫu đại diện khoảng 130.000 sinh viên.
- Mô hình: Các thuật toán học máy cổ điển và Ensemble Learning (Logistic Regression, Linear SVC, Decision Tree, Random Forest, XGBoost).

2.2 Mục tiêu nghiên cứu:

- Xây dựng luồng dữ liệu (Data Pipeline) tự động để làm phẳng (flattening) cấu trúc JSON đa cấp và hợp nhất dữ liệu đa nguồn.
- Xây dựng nhãn mức độ tương tác từ dữ liệu không có label.
- Trích xuất đặc trưng từ hành vi giai đoạn đầu.
- Huấn luyện và so sánh hiệu suất của 4 mô hình học có giám sát, xử lý triệt để bài toán mất cân bằng lớp (class imbalance) bằng kỹ thuật SMOTE.
- Trích xuất Feature Importance để xây dựng Dashboard cảnh báo sớm.

3. MỤC TIÊU THỰC NGHIỆM

- **Đánh giá khả năng dự báo chuỗi thời gian:** Xác định mô hình học có giám sát nào tối ưu nhất trong việc xử lý dữ liệu log hành vi tuần tự để dự báo nhãn tương tác.

- **Đánh giá hiệu quả của kỹ thuật cân bằng dữ liệu:** So sánh hiệu suất mô hình (đặc biệt là Recall của lớp "Low Engagement") trước và sau khi áp dụng SMOTE trên tập dữ liệu có phân bổ nhãn 1 : 1 : 1.

- Xây dựng pipeline hoàn chỉnh từ dữ liệu thô đến mô hình dự đoán, sao cho:
    1. Đạt độ chính xác dự đoán khoảng **0.6 +**
    2. Xác định các đặc trưng ảnh hưởng đến engagement
    3. Đảm bảo mô hình có khả năng giải thích

4. MÔI TRƯỜNG THỰC NGHIỆM

- Platform: Google Colab / Kaggle
- Ngôn ngữ: Python 3.14
- Thư viện chính:
    - pandas: Xử lý dữ liệu
    - numpy: Tính toán ma trận
    - matplotlib & seaborn: Trực quan hóa
    - scikit-learn: Machine Learning
    - scipy: Phân tích thống kê

5. ĐƠN VỊ PHÂN TÍCH VÀ PHẠM VI DỰ BÁO

- **Đơn vị phân tích (Unit of Analysis):** Một bản ghi (record) trong tập dữ liệu huấn luyện đại diện cho hành vi của một sinh viên U_i trong một khoảng thời gian cụ thể (tuần W_t).

- **Phạm vi dự báo (Prediction Scope):** Dự đoán mức độ tương khi học tập online trên nền tảng XuetangX dựa trên hành vi trong 28 ngày đầu.

6. CHIẾN LƯỢC GÁN NHÃN

Do không có ground truth, nhãn được xây dựng bằng phương pháp **Weighted Engagement Score (WES)**, quy trình bao gồm các bước:

i. **Gom dữ liệu theo user_id và tính các đặc trưng toàn khóa như:**

1. total_study_time
2. avg_score
3. accuracy_rate
4. attempts
5. total_forum_activities
6. …

ii. **Áp dụng:** Laplace smoothing cho accuracy và chuẩn hóa bằng RobustScaler.

iii. **Tính trọng số bằng:** Entropy Weight Method (EWM) sau đó tính điểm WES bằng công thức:

$$\mathbf{WES = \Sigma(feature \times weight)}$$

iv. **Mapping nhãn:** Sử dụng phân vị:

- 0 – 33% → Low Engagement
- 33 – 67% → Medium Engagement
- 67 – 100% → High Engagement

7. QUY TRÌNH THỰC NGHIỆM

7.1. Giai đoạn 1: Định hình và trích xuất đặc trưng Time-Series

Hành vi học tập của người học mang tính tiến trình theo thời gian. Việc trích xuất đặc trưng trong giai đoạn đầu là nền tảng để xây dựng mô hình dự đoán sớm mức độ tương tác.

i. **Xác định mốc thời gian học (Enrollment Time):** Với mỗi học viên, xác định thời điểm bắt đầu học enroll_time. Trong trường hợp dữ liệu thiếu thông tin này, sử dụng thời điểm hành vi đầu tiên (min(action_time)) làm mốc thay thế nhằm đảm bảo tính nhất quán

ii. **Chuẩn hóa trục thời gian (Time Alignment):** Tính toán số ngày kể từ khi bắt đầu học:

days_since_enroll = action_time - enroll_time

Việc chuẩn hóa này giúp đưa toàn bộ học viên về cùng một hệ quy chiếu thời gian.

iii. **Cắt lát dữ liệu theo cửa sổ thời gian (Time Windowing)**: chỉ giữ lại các hành vi trong khoảng từ 0 đến 28 ngày đầu. Đây là bước quan trọng để mô phỏng bài toán **early prediction**, đảm bảo mô hình chỉ sử dụng thông tin sớm.

iv. Tổng hợp đặc trưng hành vi (Feature Aggregation): Thực hiện groupby(user_id) để chuyển dữ liệu từ dạng event-level sang user-level, tạo các đặc trưng:

a. **Đặc trưng tĩnh:** Giới tính, năm sinh, trường học, độ dài khóa học đã đăng ký.

b. **Đặc trưng học tập:**

- attempts_4w: tổng số lần làm bài
- is_correct_4w: tổng số lần làm đúng
- score_4w: điểm trung bình
- accuracy_rate_4w: tỷ lệ đúng

c. **Đặc trưng tương tác:**

- rep_counts: số phản hồi
- cmt_counts: số bình luận
- seq: mức độ hoạt động (proxy cho số lượng và mật độ sự kiện)

Các đặc trưng này phản ánh đầy đủ mức độ tham gia của học viên trong giai đoạn đầu của khóa học.

7.2. Giai đoạn 2: Khởi tạo nhãn chuẩn (Ground Truth) bằng Weighted Engagement Score (WES)

Do dữ liệu không có nhãn sẵn, đề tài xây dựng nhãn mức độ tương tác dựa trên phương pháp định lượng từ hành vi học tập toàn khóa học.

i. **Xây dựng đặc trưng toàn khóa (Full-course Aggregation):**
Từ toàn bộ dữ liệu (không giới hạn 28 ngày), tính các đặc trưng tổng hợp:
- tổng thời gian học
- điểm trung bình
- tỷ lệ đúng
- số lần làm bài
- mức độ tương tác (forum activity)

ii. **Chuẩn hóa dữ liệu (Robust Normalization):** Áp dụng **RobustScaler** để đưa các đặc trưng về cùng thang đo và giảm ảnh hưởng của outlier.

iii. **Xác định trọng số đặc trưng (Entropy Weight Method - EWM):** Sử dụng phương pháp entropy để tính toán mức độ thông tin của từng đặc trưng, từ đó xác định trọng số khách quan cho mỗi biến.

iv. **Tính Weighted Engagement Score (WES):**
Điểm engagement của mỗi học viên được tính bằng:

$$\mathbf{WES_i = \Sigma\ (x_i_j \times w_j)}$$

Trong đó:

- x_i_j: giá trị đặc trưng đã chuẩn hóa
- w_j: trọng số của đặc trưng j

v. **Phân nhãn theo phân vị (Percentile-based Labeling):** Dựa trên phân bố của WES, chia thành 3 nhóm:
- Low Engagement (0 – 33%)
- Medium Engagement (33 – 67%)
- High Engagement (67 – 100%)

Phương pháp này đảm bảo việc gán nhãn mang tính dữ liệu-driven, không phụ thuộc giả định chủ quan.

7.3. Giai đoạn 3: Phân chia tập dữ liệu và Xử lý mất cân bằng (SMOTE)

Để đảm bảo mô hình học được phân phối dữ liệu thực tế và tránh sai lệch đánh giá, việc chia dữ liệu và xử lý mất cân bằng được thực hiện cẩn trọng.

i. **Stratified Split (Phân chia có kiểm soát):**Dữ liệu được chia thành:

Train: 80% | Validation: 10% | Test: 10%

Áp dụng **Stratified Sampling** để đảm bảo phân phối nhãn (Low, Medium, High) được giữ nguyên trong từng tập con, tránh hiện tượng lệch lớp.

ii. **Xử lý mất cân bằng bằng SMOTENC:** Do dữ liệu có sự chênh lệch giữa các lớp, đặc biệt là lớp Low và Medium, áp dụng: **SMOTENC (Synthetic Minority Over-sampling Technique for Categorical data)**

- Chỉ áp dụng trên **tập train.**
- Tạo thêm các mẫu nhân tạo cho các lớp thiểu số.
- Giữ nguyên tập validation và test để phản ánh đúng phân phối thực tế.
- Đảm bảo không xảy ra Data Leakage**:** Việc áp dụng SMOTE sau khi chia dữ liệu giúp tránh việc thông tin từ tập test "rò rỉ" vào quá trình huấn luyện, đảm bảo kết quả đánh giá phản ánh đúng hiệu năng khi triển khai thực tế.

7.4. Giai đoạn 4: Huấn luyện và tối ưu mô hình (Supervised Learning)

Trong giai đoạn này, dữ liệu đầu vào được chia làm 3 tập: Train (103.612 mẫu), Validation (12.952 mẫu) và Test (12.952 mẫu) với 7 đặc trưng cấu thành. Thực nghiệm đã tiến hành huấn luyện và so sánh hiệu năng trực tiếp của 5 thuật toán học máy: Logistic Regression, Linear SVC, Decision Tree, Random Forest và XGBoost.

Bảng xếp hạng hiệu năng các thuật toán trên tập Validation:

Mô hình huấn luyện	**Accuracy**	**Balanced Accuracy**	**F1 Macro**	**F1 Weighted**	**Recall Low_Engagement**	**Precision Low_Engagement**	**F1 Low_Engagement**
Logistic Regression	0.6088	0.6060	0.5016	0.5033	**0.0117**	0.1645	0.0218
Linear SVC	0.6141	0.6113	0.4970	0.4987	0.0021	0.2000	0.0042
Decision Tree	0.6230	0.6204	0.5012	0.5029	0.0000	0.0000	0.0000
Random Forest	0.6228	0.6202	0.5017	0.5034	0.0009	0.2500	0.0019
XGBoost	0.6231	0.6205	0.5013	0.5030	0.0000	0.0000	0.0000

Lý do thuật toán Logistic Regression được lựa chọn triển khai:

- Trong hệ thống cảnh báo sớm, việc bỏ sót sinh viên có nguy cơ (False Negative) mang lại rủi ro cao hơn việc cảnh báo nhầm (False Positive). Do đó, tiêu chí tối thượng để chọn mô hình là chỉ số Recall của nhóm Low_Engagement.
- Dựa trên kết quả thực nghiệm, Logistic Regression là thuật toán chiến thắng do đạt chỉ số Recall_Low_Engagement cao nhất (0.0117). Mặc dù các thuật toán dạng cây (Decision Tree, Random Forest, XGBoost) đạt Accuracy và Balanced Accuracy

nhỉnh hơn, nhưng khả năng nhận diện lớp Low_Engagement của chúng gần như bằng 0.

- Đánh giá trên tập Test độc lập cho thấy mô hình Logistic Regression đạt độ chính xác (Accuracy) 0.6106, Balanced Accuracy 0.6077 và duy trì Recall_Low_Engagement ở mức 0.0136. Mô hình được xuất ra dưới dạng tệp deployment_bundle.pkl để phục vụ triển khai.

7.5. Giai đoạn 5: Hệ thống tiêu chuẩn đánh giá (Evaluation Metrics)

a) Các độ đo hiệu suất mô hình (Khách quan)

Với bài toán Multi-class Classification và dữ liệu có sự chênh lệch nhãn gốc, độ chính xác tổng thể không phải là thước đo đáng tin cậy nhất. Kịch bản thực nghiệm sẽ sử dụng các độ đo sau trên tập test:

i. **Confusion Matrix:** Quan sát trực quan số lượng sinh viên bị dự đoán sai từ Low lên High.

ii. **F1-Score:**

- *Macro F1:* Trung bình cộng F1 của 3 nhãn, xử lý công bằng cả lớp Medium dù số lượng ít.
- *Weighted F1:* Trung bình F1 có tính đến trọng số tương đương với số lượng mẫu của từng nhãn.

iii. **Precision - Recall:** Đặc biệt chú trọng vào độ đo Recall của lớp Low. Trong ngữ cảnh giáo dục, ưu tiên cảnh báo nhầm một sinh viên bình thường - False Positive còn hơn là bỏ sót một sinh viên đang sắp bỏ học - False Negative.

iv. **ROC-AUC (One-vs-Rest):** Đo lường khả năng phân tách của mô hình giữa một lớp bất kỳ với các lớp còn lại. AUC > 0.85 được xem là mô hình có tính ứng dụng cao.

v. **Feature Importance:** Trích xuất từ cây quyết định của XGBoost/CatBoost để xác định Top 5 đặc trưng có tính quyết định nhất, làm cơ sở khoa học để thiết kế các chỉ số trên màn hình Dashboard cảnh báo.

b) Các tiêu chí đánh giá chất lượng dữ liệu (Data Quality Assessment)

Việc đánh giá mô hình không chỉ dừng ở đầu ra, mà còn phải đánh giá chất lượng dữ liệu đầu vào và xuyên suốt vòng đời dữ liệu, đảm bảo mô hình hoạt động trên nền tảng vững chắc theo các khía cạnh (dimensions) được định nghĩa trong Data Quality Framework.

Hệ thống đánh giá sẽ áp dụng phương pháp đo lường khách quan cho các khía cạnh sau:

- **Tính chính xác (Accuracy của dữ liệu):**
  - *Phương pháp khách quan:* Sử dụng phân tích thống kê (tỷ lệ lỗi, độ lệch chuẩn) để đảm bảo các giá trị hành vi (như attempts, score) phản ánh chính xác tương tác thực tế của sinh viên trên hệ thống.
  - So sánh với nguồn dữ liệu đáng tin cậy (ví dụ: đối chiếu log với cơ sở dữ liệu điểm số chính thức của trường) để xác minh tính chính xác.
- **Tính đầy đủ (Completeness):**
  - *Phương pháp khách quan:* Phân tích tỷ lệ dữ liệu thiếu (missing values) ở các trường quan trọng như enroll_time (như đã thấy trong log, hệ thống đã phải xử lý việc thiếu cột này).
  - Kiểm tra tính đầy đủ của thông tin hồ sơ sinh viên (age, gender, school) trước khi đưa vào huấn luyện mô hình.
- **Tính nhất quán (Consistency):**
  - *Phương pháp khách quan:* Đảm bảo định dạng thời gian (create_time_x, create_time_y) đồng nhất trên toàn bộ tập dữ liệu được tổng hợp từ nhiều bảng phân tán khác nhau.
  - Thực hiện phân tích độ tương quan để đảm bảo các thuộc tính dữ liệu không mâu thuẫn lẫn nhau.
- **Tính hợp lệ (Validity):**
  - *Phương pháp khách quan:* Kiểm tra các giá trị ngoại lệ (outliers) hoặc các giá trị không hợp lý (ví dụ: score lớn hơn 100%, hoặc thời gian học âm) bằng các phương pháp như IQR hoặc z-score.
- **Tính kịp thời (Timeliness):**
  - Trong bài toán Early Warning System, dữ liệu cần phải được cập nhật và xử lý với độ trễ thấp nhất có thể.

- *Phương pháp khách quan:* Tính toán độ trễ từ khi sinh viên thực hiện hành vi đến khi hệ thống trích xuất Time-window features và đưa ra dự báo. Độ trễ cao có thể làm mất đi giá trị của việc "cảnh báo sớm".

Bằng việc kết hợp các chỉ số hiệu suất mô hình học máy với các tiêu chuẩn chất lượng dữ liệu doanh nghiệp, hệ thống không chỉ lựa chọn được mô hình phù hợp nhất mà còn đảm bảo độ tin cậy và khả năng triển khai thực tế của toàn bộ quy trình.

7.6. Giai đoạn 6: Khả năng giải thích mô hình: Model Interpretability

i. Mục tiêu của giai đoạn

Trong khai phá dữ liệu giáo dục (EDM), một mô hình có độ chính xác 99% nhưng hoạt động như một black-box sẽ bị loại bỏ khi triển khai. Giảng viên cần biết tại sao hệ thống đưa ra cảnh báo để có phương án sư phạm phù hợp. Ví dụ: Sinh viên rớt nhóm Low do không xem video hay do làm bài tập điểm kém? Giai đoạn này chuyển đổi kết quả toán học thành tri thức nghiệp vụ.

ii. Kỹ thuật thực hiện chi tiết

Áp dụng hai cấp độ giải thích từ tổng quát đến cục bộ:

a. **Trích xuất độ quan trọng của đặc trưng (Global Interpretability - Feature Importance):**

- **Kỹ thuật:** Sử dụng chỉ số Gini Impurity giảm dần (Mean Decrease in Impurity) hoặc chỉ số Information Gain được cung cấp sẵn từ các mô hình dạng cây (Random Forest, XGBoost).
- **Thực thi: Độ quan trọng của đặc trưng (Feature Importance):** Thông qua quá trình phân tích 6 đặc trưng đầu vào, hệ thống trích xuất Top 5 yếu tố có độ ảnh hưởng lớn nhất đến mức độ tương tác, bao gồm theo thứ tự: accuracy_rate_4w, score_4w, num_courses, is_correct_4w và attempts_4w. Kết quả này được dùng làm tham số cứng để vẽ các biểu đồ cảnh báo trên màn hình Dashboard.

b. **Giá trị SHAP (Local & Global Interpretability):**

- Dữ liệu SHAP được lấy mẫu ngẫu nhiên từ 1000 bản ghi trong tập Test.
- **Giải thích toàn cục (Global Interpretability):** Hệ thống xuất biểu đồ, cung cấp cái nhìn tổng thể về cách các đặc trưng như tỷ lệ làm bài đúng hay số lượng khóa học điều phối xác suất phân lớp trên toàn bộ mẫu.

- **Giải thích cục bộ (Local Interpretability):** Hệ thống thực hiện trích xuất báo cáo giải thích cho từng sinh viên cụ thể. Biểu đồ này phân tách chính xác các yếu tố làm tăng hoặc giảm điểm rủi ro của sinh viên, hỗ trợ thiết lập các hành động can thiệp học thuật kịp thời.