ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHAI PHÁ DỮ LIỆU DOANH NGHIỆP

BÁO CÁO ĐỒ ÁN

DỰ ĐOÁN LOẠI HỌC VIÊN DỰA TRÊN DỮ LIỆU HÀNH VI HỌC TẬP - 3 NHÃN

GVHD: ThS. Nguyễn Thị Anh Thư

Lớp: DS317.Q21.VB2

Nhóm 3

Họ và tên	**MSSV**
Trần Thị Minh Hương	24540011
Bùi Hoàng Khánh Linh	24540015
Nguyễn Thanh Sơn	24540022
Huỳnh Ngọc Tài	24540023
Lê Quốc Thái	24540024

Tp. Hồ Chí Minh, 05/2026

LỜI CẢM ƠN

Chúng tôi xin chân thành cảm ơn cô giáo, ThS. Nguyễn Thị Anh Thư, người đã định hướng, giúp đỡ, trực tiếp hướng dẫn và tận tình chỉ bảo chúng tôi trong suốt quá trình nghiên cứu, xây dựng và hoàn đồ án này.

Chúng tôi cũng xin được cảm ơn tới gia đình, những người thân và bạn bè thường xuyên quan tâm, động viên, chia sẻ kinh nghiệm, cung cấp các tài liệu hữu ích trong thời gian học tập, nghiên cứu cũng như trong suốt quá trình thực hiện đồ án.

TP. HCM, ngày 4 tháng 5 năm 2026

ĐÁNH GIÁ CỦA GIẢNG VIÊN HƯỚNG DẪN

……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……

TP. HCM, ngày 4 tháng 5 năm 2026

GVHD

Nguyễn Thị Anh Thư

MỤC LỤC

MỤC LỤC **4**
DANH MỤC BẢNG **7**
DANH MỤC HÌNH ẢNH **8**
Chương 1: Giới thiệu bài toán **9**
1.1 Giới thiệu 9
1.2 Định nghĩa bài toán 9
1.2.1 Ngữ cảnh 9
1.2.2 Đầu vào bài toán 9
1.2.3 Đầu ra bài toán 10
1.3 Mục tiêu và phạm vi ứng dụng 10
1.3.1 Mục tiêu 10
1.3.2 Đối tượng hướng đến 10
1.3.3 Phạm vi thực hiện (scope) 10
1.4 Khó khăn và thách thức 11
Chương 2: Các công trình nghiên cứu liên quan **12**
2.1 Công trình nghiên cứu 12
2.1.1 Mô tả phương pháp: 12
2.2. Cơ sở học thuật của phương pháp đã nghiên cứu để áp dụng vào đề tài 15
2.2.1. Mô tả dữ liệu sử dụng 15
2.2.2. Xây dựng các hoạt động học tập phù hợp để làm thuộc tính 16
2.2.3. Chuyển đổi dữ liệu 16
2.2.4. Tính trọng số hoạt động 17
2.2.5 Chuẩn hóa dữ liệu (Scaling) 18
2.2.6 Gán nhãn sinh viên 19
2.2 Xác định định hướng cho bài toán 19
Chương 3: Cơ sở lý thuyết **21**
3.1 Mô hình truyền thống 21
3.1.1 Logistic Regression 21
3.1.2 Random Forest Classifier 22
3.1.3 XGBoost 23
3.1.4 CatBoost 24
3.2 Mô hình học sâu 25
3.2.1 Fully Connected Neural Network (FCNN) 25
3.2.2 Long Short-Term Memory (LSTM) 26
3.3 Phân cụm và gán nhãn dữ liệu 27
3.3.1 K-Means Clustering 27
3.4 Độ đo đánh giá 28

Chương 4: Tìm hiểu và Khám phá dữ liệu 29
4.1 Giới thiệu bộ dữ liệu MOOCCubeX 29
4.2 Khám phá tập dữ liệu user.json 29
4.3 Khám phá tập dữ liệu user-video.json 29
4.4 Khám phá tập dữ liệu comment.json 30
4.5 Khám phá tập dữ liệu reply.json 30
4.6. Quá trình tổng hợp dữ liệu 30
a. Nhóm đặc trưng hồ sơ (User Profile Features) 32
b. Nhóm đặc trưng hành vi học tập (Learning Behavior Features) 33
c. Nhóm đặc trưng tương tác xã hội (Social Interaction Features) 35
4.7 Khám phá dữ liệu tổng quan 37
4.8 Tri thức rút ra từ quá trình khám phá 37
4.9 Gợi mở tiền đề cho phương pháp đề xuất 38
Chương 5: Phương pháp đề xuất 39
5.1 Tổng quan quy trình 39
5.2 Mối liên hệ giữa các giai đoạn 42
Chương 6: Kiến trúc Data Engineering Pipeline trên AWS 44
6.1 Giới thiệu 44
6.2 Kiến trúc tổng thể của Pipeline 44
(1) Amazon S3 – Tầng lưu trữ dữ liệu thô (Raw Data Storage) 44
(2) AWS Lambda – Tầng xử lý và gắn nhãn sơ bộ (Processing & Labeling) .. 45
(3) Amazon Athena – Tầng catalog và truy vấn dữ liệu (Query & Catalog Data) 47
(4) Amazon SageMaker – Tầng huấn luyện AI/ML (Machine Learning Models) 48
(5) Dashboard BI – Tầng trực quan hóa và hỗ trợ ra quyết định (Data Visualization & Insights) 50
6.3 Đánh giá học thuật và ý nghĩa hệ thống 56
Chương 7: Kịch bản thực nghiệm 57
7.1 Giới thiệu bài toán 57
7.2. Phạm vi và mục tiêu nghiên cứu 57
7.2.1 Phạm vi nghiên cứu: 57
7.2.2 Mục tiêu nghiên cứu: 57
7.3. Mục tiêu thực nghiệm 58
7.4. Môi trường thực nghiệm 58
7.5. Đơn vị phân tích và phạm vi dự báo 58
7.6. CHIẾN LƯỢC GÁN NHÃN 58
7.7. QUY TRÌNH THỰC NGHIỆM 59
7.7.1. Giai đoạn 1: Định hình và trích xuất đặc trưng Time-Series 59

7.7.2. Giai đoạn 2: Khởi tạo nhãn chuẩn (Ground Truth) bằng Weighted Engagement Score (WES) 60
7.7.3. Giai đoạn 3: Phân chia tập dữ liệu và Xử lý mất cân bằng (SMOTE) 61
7.7.4. Giai đoạn 4: Huấn luyện và tối ưu mô hình (Supervised Learning) 61
7.7.5. Giai đoạn 5: Hệ thống tiêu chuẩn đánh giá (Evaluation Metrics) 62
7.7.6. Giai đoạn 6: Khả năng giải thích mô hình: Model Interpretability 64
Chương 8: Kết luận và hướng phát triển 66
8.1 Kết luận 66
8.2 Đánh giá các phương pháp 66
8.2.1. Weighted Engagement Score (WES) 67
8.2.2. Logistic Regression 67
8.2.3. Random Forest 67
8.2.4. XGBoost 68
8.2.5. CatBoost 68
8.2.6. LSTM (Deep Learning) 69
8.2.7. K-Means Clustering 69
8.3 Hướng phát triển tiềm năng 69
8.3.1. Cải tiến phương pháp gán nhãn 69
8.3.2. Khai thác dữ liệu chuỗi sâu hơn 70
8.3.3. Cải thiện khả năng dự báo sớm 70
8.3.4. Tối ưu mô hình 70
8.3.5. Mở rộng hệ thống thực tế 70
8.3.6. Mở rộng dữ liệu 70

DANH MỤC HÌNH ẢNH

Hình 3.1 – Mô hình Logistic Regression 21
Hình 3.2 – Mô hình Random Forest 22
Hình 3.4 – Mô hình CatBoost 24
Hình 3.5 – Mô hình FCNN (Fully Connected Neural Network) 25
Hình 3.6 – Mô hình LSTM (Long Short-Term Memory) 26
Hình 3.7 – Mô hình K-Means Clustering 27
Hình 4.1 – Hình dữ liệu sau khi tổng hợp 31
Hình 4.2 – Các thuộc tính tĩnh 32
Hình 4.3 – Các thuộc tính động 1 33
Hình 4.4 – Các thuộc tính động 2 35
Hình 4.5 – Các thuộc tính động 3 36
Hình 5.1 - Sơ đồ tổng thể phương pháp đề xuất – pipeline từ dữ liệu đầu vào đến đánh giá mô hình 39
Hình 5.3 - Time series 40
Hình 5.3 - SMOTE 41
Hình 6.1: Sơ đồ AWS Data Engineering Pipeline – gồm các tầng S3, Lambda, Athena, SageMaker và Dashboard BI. 44
Hình 6.3: Code deploy Lambda để làm sạch và tính toán dữ liệu lấy từ S3. 46
Hình 6.4: CloudWatch để theo dõi log quá trình code trigger dữ liệu. 46
Hình 6.5: CloudWatch để theo dõi log quá trình code trigger dữ liệu. 47
Hình 6.6 - CloudWatch để theo dõi log quá trình code trigger dữ liệu. 50
Hình 6.7 - Triển khai SageMaker Notebook chạy K-Means clustering và ánh xạ nhãn ML-Low, ML-Medium, ML-High) 50
Hình 6.8 - Sau khi AI dán nhãn file được lưu lại vào S3. 50
Hình 6.9 - Dashboard xây dựng bằng SageMaker Notebook kết hợp Ngrok 1.1 51
Hình 6.10 - Dashboard xây dựng bằng SageMaker Notebook kết hợp Ngrok 1.2 51
Hình 6.11 - Dashboard trang phân tích hành vi 1 52
Hình 6.12 - Dashboard trang phân tích hành vi 2 52
Hình 6.13 - Dashboard trang phân tích hành vi 3 53
Hình 6.14 - Dashboard chi tiết hồ sơ tương tác của học viên. 53
Hình 6.15 - Dashboard phân tích xu hướng hành vi theo thời gian 1 54
Hình 6.16 - Dashboard phân tích xu hướng hành vi theo thời gian 2 54
Hình 6.16 - Dashboard hỗ trợ ra quyết định 1 55
Hình 6.17 - Dashboard hỗ trợ ra quyết định 2 55

DANH MỤC BẢNG

Bảng 7.1 Bảng xếp hạng hiệu năng các thuật toán trên tập Validation:..... 63

Chương 1: Giới thiệu bài toán

1.1 Giới thiệu

Sự phát triển mạnh mẽ của các nền tảng học trực tuyến quy mô lớn (Massive Open Online Courses – MOOC) đã mở ra cơ hội học tập cho hàng triệu người trên toàn thế giới. Người học có thể tiếp cận các khóa học chất lượng cao mà không bị giới hạn bởi không gian hay thời gian. Tuy nhiên, sự bùng nổ này cũng tạo ra một lượng dữ liệu khổng lồ về hành vi học tập của người học, bao gồm việc xem video bài giảng, làm bài tập, tham gia thảo luận, gửi bình luận và phản hồi.

Điểm đặc biệt của dữ liệu hành vi học tập là chúng tồn tại dưới dạng nhật ký sự kiện (event log data). Mỗi bản ghi chỉ phản ánh một hành động cụ thể tại một thời điểm nhất định. Điều này khiến dữ liệu ban đầu rất rời rạc, khó khai thác trực tiếp nếu không có bước tổng hợp và chuyển đổi thành đặc trưng định lượng. Trong khi đó, mức độ tham gia học tập (engagement) lại là một biến ẩn, không thể quan sát trực tiếp mà chỉ có thể được suy luận thông qua các hành vi cụ thể. Chính vì vậy, việc phân tích dữ liệu hành vi học tập để dự đoán loại học viên theo mức độ tham gia trở thành một bài toán quan trọng, vừa có ý nghĩa học thuật vừa mang giá trị thực tiễn cao.

1.2 Định nghĩa bài toán

1.2.1 Ngữ cảnh

Trong môi trường MOOC, người học có sự đa dạng rất lớn về động lực, khả năng và mức độ tham gia. Một số học viên thể hiện sự tích cực rõ rệt khi thường xuyên xem video, hoàn thành bài tập và tham gia thảo luận, trong khi một số khác chỉ tham gia ở mức tối thiểu, thậm chí bỏ dở giữa chừng. Sự khác biệt này tạo ra nhu cầu cấp thiết phải phân loại học viên theo mức độ tham gia để giảng viên và hệ thống quản lý học tập có thể đưa ra các chiến lược hỗ trợ phù hợp.

1.2.2 Đầu vào bài toán

Đầu vào của bài toán là dữ liệu hành vi học tập được trích xuất từ bộ dữ liệu **MOOCCubeX**, bao gồm:

- **user.json**: thông tin hồ sơ người học (user_id, giới tính, trường học, năm sinh, số lượng khóa học đã đăng ký).
- **user-video.json**: hành vi xem video, thời gian xem, số lượng video đã xem.
- **user-problem.json**: hành vi làm bài tập, kết quả đúng sai, số lần thử, điểm số.
- **comment.json**: dữ liệu bình luận của người học.

- **reply.json**: dữ liệu phản hồi trong thảo luận.

1.2.3 Đầu ra bài toán

Đầu ra mong muốn là mô hình phân loại học viên thành ba nhóm:

- **Low Engagement (LE)**: nhóm có mức độ tham gia thấp, ít xem video, ít làm bài tập, ít tương tác.
- **Moderate Engagement (ME)**: nhóm có mức độ tham gia trung bình, tham gia một số hoạt động nhưng chưa đều đặn.
- **High Engagement (HE)**: nhóm có mức độ tham gia cao, tích cực trong hầu hết các hoạt động học tập.

1.3 Mục tiêu và phạm vi ứng dụng

1.3.1 Mục tiêu

Mục tiêu chính của nghiên cứu là phân tích dữ liệu hành vi học tập từ MOOCCubeX, xây dựng đặc trưng định lượng phản ánh mức độ tham gia học tập, gán nhãn học viên theo ba mức độ tham gia và huấn luyện các mô hình học máy để dự đoán loại học viên. Ngoài ra, nghiên cứu còn hướng đến việc đánh giá hiệu quả của các mô hình học máy truyền thống và học sâu trong việc phân loại học viên, từ đó rút ra những nhận xét về ưu nhược điểm của từng phương pháp.

1.3.2 Đối tượng hướng đến

Đối tượng mà nghiên cứu hướng đến bao gồm:

- **Giảng viên và nhà quản lý giáo dục**: sử dụng kết quả phân loại để theo dõi tiến độ học tập của từng nhóm học viên, từ đó đưa ra các chiến lược hỗ trợ phù hợp.
- **Người học**: nhận được sự hỗ trợ cá nhân hóa, phù hợp với mức độ tham gia của mình.
- **Nhà nghiên cứu**: có thêm dữ liệu và phương pháp để phát triển các mô hình phân tích hành vi học tập.

1.3.3 Phạm vi thực hiện (scope)

Phạm vi thực hiện của nghiên cứu tập trung vào việc sử dụng dữ liệu từ bộ MOOCCubeX, bao gồm các bảng user, user-video, user-problem, comment và reply. Nghiên cứu tập trung vào ba loại hành vi chính: xem video, làm bài tập và tương tác xã

hội. Các thuật toán học máy truyền thống như Logistic Regression, Random Forest, SVM, KNN, XGBoost và các mô hình học sâu như Fully Connected Neural Network (FCNN) và Long Short-Term Memory (LSTM) sẽ được áp dụng. Kết quả sẽ được đánh giá bằng các độ đo chuẩn như Precision, Recall và F1-score.

1.4 Khó khăn và thách thức

Nghiên cứu đối mặt với nhiều khó khăn và thách thức. Thứ nhất, dữ liệu MOOCCubeX có quy mô rất lớn, với hàng triệu bản ghi và nhiều thuộc tính, đòi hỏi khả năng xử lý dữ liệu hiệu quả. Thứ hai, dữ liệu không cân bằng, khi số lượng học viên thuộc nhóm tương tác thấp thường nhiều hơn nhóm tương tác cao, gây khó khăn cho mô hình phân loại. Thứ ba, dữ liệu có thể bị nhiễu và thiếu, do hành vi học tập có thể bị gián đoạn hoặc dữ liệu log không đầy đủ, không nhất quán. Thứ tư, dữ liệu có đặc trưng đa chiều, bao gồm cả đặc trưng tĩnh (hồ sơ người học) và đặc trưng động (hành vi học tập), cần được tích hợp hợp lý. Cuối cùng, việc định nghĩa mức độ tham gia học tập là một thách thức lớn, bởi engagement là một biến ẩn, việc gán nhãn dựa trên phân vị có thể chưa phản ánh đầy đủ bản chất hành vi.

Chương 2: Các công trình nghiên cứu liên quan

2.1 Công trình nghiên cứu

Đề tài áp dụng phương pháp từ nghiên cứu *"Identifying Weekly Student Engagement Patterns in E-Learning via K-Means Clustering and Label-Based Validation"*. Nghiên cứu này đề xuất chỉ số **Weighted Engagement Score (WES)** nhằm khắc phục hạn chế của việc tính tần suất đơn thuần bằng cách gán trọng số cho hoạt động dựa trên mức độ phổ biến của chúng

Thuật toán được sử dụng trong công trình liên quan: **Thuật toán tính điểm tương tác có trọng số (Weighted Engagement Score Calculation).**

2.1.1 Mô tả phương pháp:

Trong nghiên cứu "Identifying Weekly Student Engagement Patterns in E-Learning via K-Means Clustering and Label-Based Validation", tác giả đề xuất một phương pháp định lượng mức độ tham gia học tập của sinh viên dựa trên hành vi trực tuyến, thông qua việc xây dựng chỉ số **Weighted Engagement Score**. Phương pháp này nhằm khắc phục hạn chế của cách tiếp cận dựa trên tần suất đơn thuần, bằng cách gán trọng số cho từng loại hoạt động học tập dựa trên mức độ phổ biến của chúng trong toàn bộ dữ liệu.

Đầu vào của thuật toán:

Thuật toán sử dụng ba thành phần dữ liệu chính:

- **Dữ liệu hoạt động của sinh viên (Student Activity Data):** Bao gồm các bản ghi hành vi của từng sinh viên trong suốt quá trình học, thường được tổ chức theo đơn vị thời gian (ví dụ: theo tuần). Mỗi bản ghi thể hiện trạng thái tham gia của sinh viên đối với từng loại hoạt động, được mã hóa dưới dạng nhị phân.
- **Tập các hoạt động được theo dõi (Tracked Activities):** Ký hiệu là ($A = a_1, a_2, a_3, \dots a_M$), trong đó mỗi phần tử tương ứng với một loại hành vi học tập trực tuyến (ví dụ: xem bài giảng, làm bài tập, tham gia thảo luận,...).
- **Số tuần học (Number of Weeks):** Ký hiệu là (N), đại diện cho độ dài của quá trình học tập.

Để biểu diễn dữ liệu, tác giả sử dụng biến nhị phân:

$$x_{i,a,\omega} = \begin{cases} 1 \text{ nếu sinh } viên\ i\ hoạt\ động\ a\ tại\ tuần\ \omega \\ 0\ ngược\ lại \end{cases}$$

Biến này cho phép chuyển đổi dữ liệu hành vi thành dạng cấu trúc có thể xử lý bằng các phép toán thống kê.

Bước 1: Khởi tạo

Một cấu trúc lưu trữ dạng ánh xạ (dictionary) được khởi tạo để lưu điểm tương tác của từng sinh viên, ký hiệu là: student_weighted_scores

Bước 2: Tính trọng số cho từng hoạt động

Trọng số của mỗi hoạt động được xác định dựa trên tần suất xuất hiện của hoạt động

$$\omega_\alpha = \frac{\sum_{i=1}^{S} \sum_{\omega=1}^{N} x_{i,\alpha,\omega}}{S \times N}$$

Trong đó:

- S là tổng số sinh viên
- N là số tuần học
- $x_{i,\alpha,\omega}$ là trạng thái tham gia của sinh viên (i) đối với hoạt động (α) tại tuần (ω)

Về mặt ý nghĩa, tử số của biểu thức thể hiện tổng số lần hoạt động (α) được thực hiện trong toàn bộ dữ liệu, trong khi mẫu số biểu diễn tổng số cơ hội tối đa mà hoạt động đó có thể xảy ra. Do đó, giá trị ω_α phản ánh tỷ lệ xuất hiện của hoạt động α nằm trong khoảng [0,1]. Các hoạt động có tần suất xuất hiện cao sẽ có trọng số lớn hơn, cho thấy vai trò quan trọng hơn trong quá trình học tập.

Bước 3: Tính điểm tương tác của sinh viên

Sau khi xác định được trọng số cho từng hoạt động, điểm tương tác của mỗi sinh viên được tính bằng tổng có trọng số của tất cả các hoạt động mà sinh viên đó tham gia:

$$E_i = \sum_{\alpha \in A} \sum_{\omega=1}^{N} a_{i,\alpha,\omega} \cdot \omega_\alpha$$

Trong biểu thức này, tích $a_{i,\alpha,\omega} \cdot \omega_\alpha$ đóng vai trò là cơ chế lọc và gán trọng số:

- Khi $x_{i,\alpha,\omega} = 0$, sinh viên không tham gia hoạt động, và giá trị đóng góp bằng 0

- Khi $x_{i,\alpha,\omega} = 1$, sinh viên có tham gia, và đóng góp vào tổng điểm một lượng bằng ω_α

Do đó, điểm E_i được tích lũy theo hai chiều: theo thời gian (qua các tuần) và theo loại hoạt động. Cách tính này đảm bảo rằng các hoạt động có ý nghĩa học tập cao sẽ đóng góp nhiều hơn vào điểm tổng, đồng thời phản ánh được mức độ tham gia một cách toàn diện.

Bước 4: Phân loại mức độ tham gia

Sau khi tính toán điểm tương tác cho toàn bộ sinh viên, tác giả tiến hành phân loại sinh viên thành các nhóm mức độ tham gia khác nhau dựa trên phân vị của phân phối điểm. Hàm gán nhãn được xác định như sau:

- Low engagement (LE): Bottom ~33% of score (13.86 or below);
- Moderate engagement (ME): Scores between the 33rd and 66th percentiles (greater than 13.86 and ≤ 27.72);
- High engagement (HE): Top ~33% (greater than 27.72).

Tóm tắt cách phân loại và gắn nhãn sẽ tương đương:

$$L_i = \begin{cases} Low & E_i \leq P_{low} \\ Medium & P_{low} < E_i \leq P_{high} \\ High & E_i > P_{high} \end{cases}$$

Trong đó:

- P_{low} và P_{high} là các ngưỡng phân vị (ví dụ: 33% và 66%)

Phương pháp này cho phép phân loại sinh viên dựa trên vị trí tương đối của họ trong toàn bộ phân phối dữ liệu, thay vì sử dụng các ngưỡng cố định. Điều này giúp đảm bảo tính linh hoạt và khả năng thích nghi với các tập dữ liệu có phân phối khác nhau.

Đầu ra của thuật toán: Thuật toán tạo ra hai kết quả chính

- student_weighted_cores: ánh xạ giữa sinh viên và điểm tương tác tương ứng
- student_engagement_levels: ánh xạ giữa sinh viên và mức độ tham gia (Low, Medium, High)

2.2. Cơ sở học thuật của phương pháp đã nghiên cứu để áp dụng vào đề tài

Phương pháp Weighted Engagement Score được xây dựng dựa trên nguyên lý của learning analytics, trong đó hành vi học tập được định lượng thông qua các chỉ số phản ánh mức độ tham gia. Việc sử dụng trọng số cho từng hoạt động cho phép phân biệt mức độ quan trọng giữa các loại hành vi khác nhau, thay vì giả định tất cả các hoạt động đều có giá trị như nhau.

Bên cạnh đó, việc sử dụng tổng có trọng số:

$$x_{i,\alpha,\omega} \cdot \omega_\alpha$$

giúp đảm bảo rằng chỉ những hành vi thực sự xảy ra mới đóng góp vào điểm tổng, đồng thời mức đóng góp được điều chỉnh theo mức độ phổ biến của hoạt động. Điều này mang lại một cách đánh giá tinh vi hơn so với phương pháp chỉ dựa trên số lần xuất hiện.

Cuối cùng, việc áp dụng phân vị để phân loại giúp chuẩn hóa quá trình gán nhãn, đảm bảo rằng các nhóm sinh viên được phân bổ một cách cân đối và phản ánh đúng đặc điểm phân phối của dữ liệu.

Ngưỡng phân loại cụ thể trong bài gốc:

Sinh viên được phân thành 3 nhóm dựa trên phân vị của điểm tương tác E_i:

- Low Engagement (LE): thuộc ~33% thấp nhất, $E_i \leq 13.86E$ → mức độ tham gia thấp
- Moderate Engagement (ME): nằm giữa 33% ~ 66%, $13.86 < E_i \leq 27.72$ → mức trung bình
- High Engagement (HE): thuộc ~33% cao nhất, $E_i > 27.72$ → mức độ tham gia cao

Trong đề tài Dự đoán loại học sinh dựa trên hành vi học tập này, thuật toán Weighted Engagement Score được áp dụng vào bộ dữ liệu MOOCCubeX nhằm xây dựng nhãn cho bài toán phân loại sinh viên theo mức độ tham gia học tập.

2.2.1. Mô tả dữ liệu sử dụng

Nghiên cứu sử dụng 5 tập dữ liệu chính từ MOOCCubeX

- user: chứa định danh sinh viên user_id
- user-video: ghi nhận hành vi xem video học

- user-problem: ghi nhận việc làm bài tập
- comment: dữ liệu bình luận
- reply: dữ liệu phản hồi

Các tập dữ liệu này phản ánh ba khía cạnh chính của quá trình học tập gồm:

- Tiếp thu nội dung (video)
- Thực hành (problem)
- Tương tác xã hội (comment, reply)

2.2.2. Xây dựng các hoạt động học tập phù hợp để làm thuộc tính

Từ dữ liệu gốc, xác định tập hoạt động:

A = a1, a2, a3, a4

Trong đó:

- a1: xem video
- a2: làm bài tập
- a3: bình luận
- a4: trả lời

Việc ánh xạ này giúp đưa dữ liệu thực tế về đúng định dạng của thuật toán gốc.

2.2.3. Chuyển đổi dữ liệu

Dữ liệu được biểu diễn dưới dạng biến nhị phân:

$xi, \alpha, \omega \in 0,1$

Trong đó:

- i: sinh viên
- α: loại hoạt động
- ω: tuần

Cách thực hiện:

- Gom toàn bộ log theo từng tuần
- Nếu sinh viên i có thực hiện hoạt động α trong tuần $\omega \rightarrow xi, \alpha, \omega = 1$. Ngược lại $\omega \rightarrow xi, \alpha, \omega = 0$

Quá trình xây dựng biến này được thực hiện bằng cách gom các bản ghi dữ liệu theo đơn vị tuần, sau đó kiểm tra sự xuất hiện của từng loại hoạt động đối với mỗi sinh viên trong từng khoảng thời gian. Bước tiền xử lý này đóng vai trò quan trọng trong việc chuẩn hóa dữ liệu, giúp chuyển đổi dữ liệu log phức tạp thành dạng ma trận có thể áp dụng trực tiếp vào các công thức toán học.

2.2.4. Tính trọng số hoạt động

Trọng số của mỗi hoạt động được xác định dựa trên tần suất xuất hiện của hoạt động đó trong toàn bộ dữ liệu:

$$\omega_\alpha = \frac{\sum_{i=1}^{S} \sum_{\omega=1}^{N} x_{i,\alpha,\omega}}{S \times N}$$

Trong đó:

- S: là tổng số sinh viên
- N: là tổng số tuần học
- $x_{i,\alpha,\omega}$ là trạng thái tham gia của sinh viên

Diễn giải: Tử số của biểu thức thể hiện tổng số lần hoạt động a xuất hiện trong toàn bộ dữ liệu, trong khi mẫu số biểu diễn tổng số cơ hội mà hoạt động đó có thể xảy ra. Do đó, trọng số $\omega\alpha$ phản ánh tỷ lệ xuất hiện của hoạt động a, có giá trị nằm trong khoảng từ 0 đến 1.

Trong bối cảnh dữ liệu MOOCCubeX, các hoạt động mang tính học tập cốt lõi như xem video và làm bài tập thường có tần suất xuất hiện cao, do đó có xu hướng nhận trọng số lớn hơn. Ngược lại, các hoạt động mang tính tương tác xã hội như bình luận hoặc phản hồi có thể có trọng số thấp hơn.

Tính điểm tương tác sinh viên

Điểm tương tác của mỗi sinh viên được tính bằng tổng có trọng số của các hoạt động mà sinh viên đã tham gia:

$$E_i = \sum_{\alpha \in A} \sum_{\omega=1}^{N} x_{i,\alpha,\omega} \cdot \omega_\alpha$$

Trong công thức này, tích $x_{i,\alpha,\omega} \cdot \omega_\alpha$ đóng vai trò quan trọng trong việc xác định mức đóng góp của từng hoạt động:

- Nếu sinh viên không tham gia hoạt động a tại tuần w, khi đó $x_{i,\alpha,\omega} = 0$, và giá trị đóng góp bằng 0
- Nếu sinh viên có tham gia $x_{i,\alpha,\omega} = 1$, và giá trị đóng góp bằng đúng trọng số ω_α

Do đó, mỗi lần sinh viên thực hiện một hoạt động, điểm số của họ sẽ tăng thêm một lượng tương ứng với mức độ quan trọng của hoạt động đó. Tổng hai lớp tổng ($\sum \omega$ và $\sum \alpha$) cho phép tích lũy điểm theo cả chiều thời gian và loại hoạt động.

Cách tiếp cận này giúp phản ánh đồng thời cả số lượng và chất lượng của hành vi học tập, khắc phục hạn chế của phương pháp chỉ dựa trên tần suất đơn thuần.

2.2.5 Chuẩn hóa dữ liệu (Scaling)

Việc chuẩn hóa dữ liệu được xem xét nhằm đảm bảo tính ổn định khi áp dụng các mô hình học máy.

Trong trường hợp sử dụng phương pháp phân vị để gán nhãn, việc chuẩn hóa không bắt buộc do thứ hạng tương đối của dữ liệu không thay đổi. Tuy nhiên, khi sử dụng các mô hình học máy như Logistic Regression hoặc Random Forest, việc chuẩn hóa giúp cải thiện hiệu quả học của mô hình.

Phương pháp chuẩn hóa Min-Max được áp dụng như sau:

$$E_i' = \frac{E_i - min\,(E)}{(E)\ - min\,(E)}$$

Trong đó:

- min(E) và max(E) lần lượt là giá trị nhỏ nhất và lớn nhất của tập điểm
- E_i' là giá trị sau khi chuẩn hóa, nằm trong khoảng [0,1]

Phép biến đổi này giữ nguyên thứ tự tương đối giữa các sinh viên, đồng thời đưa dữ liệu về cùng một thang đo, từ đó giúp các thuật toán học máy hoạt động hiệu quả hơn.

2.2.6 Gán nhãn sinh viên

Sau khi tính toán điểm tương tác, sinh viên được phân loại dựa trên phân vị của phân phối điểm:

$$L_i = \begin{cases} \text{Low} & E_i \le P_{33} \\ \text{Medium} & P_{33} < E_i \le P_{66} \\ \text{High} & E_i > P_{66} \end{cases}$$

- P_{33} và P_{66} lần lượt là phân vị 33% và 66%

Phương pháp phân loại này dựa trên thứ hạng tương đối của sinh viên trong toàn bộ tập dữ liệu, thay vì sử dụng các ngưỡng cố định. Nhờ đó, quá trình gán nhãn trở nên linh hoạt và thích nghi tốt với đặc điểm phân phối của dữ liệu thực tế.

Ba nhãn được sử dụng để gán tương đương sau khi phân loại được học viên theo công thức trên:

- Low: nhóm ít tham gia
- Medium: nhóm trung bình
- High: nhóm tích cực

Phương pháp Weighted Engagement Score đóng vai trò là bước trung gian quan trọng trong toàn bộ pipeline xử lý dữ liệu:

$$Raw\ Data\ \rightarrow x_{i,\alpha,\omega} \rightarrow \omega_{\alpha} \rightarrow E_i \rightarrow L_i$$

Thông qua quy trình này, dữ liệu hành vi thô được chuyển đổi thành các đặc trưng định lượng có ý nghĩa và cuối cùng được sử dụng để gán nhãn cho từng sinh viên. Các nhãn này sẽ đóng vai trò là biến mục tiêu trong bài toán phân loại, cho phép áp dụng các phương pháp học có giám sát trong các bước tiếp theo của nghiên cứu.

2.2 Xác định định hướng cho bài toán

Dựa trên các công trình nghiên cứu liên quan, đặc biệt là phương pháp Weighted Engagement Score, đề tài này xác định hướng đi cụ thể cho bài toán phân loại học viên trong hệ thống MOOC như sau:

Thứ nhất, **áp dụng WES để gán nhãn dữ liệu**. Bộ dữ liệu MOOCCubeX vốn tồn tại dưới dạng log sự kiện, chưa có nhãn rõ ràng về mức độ tham gia. Do đó, việc sử dụng WES để chuyển đổi dữ liệu hành vi thô thành đặc trưng định lượng và gán nhãn cho từng học viên là bước trung gian quan trọng, giúp chuẩn hóa dữ liệu và tạo biến mục tiêu cho bài toán phân loại.

Thứ hai, **kết hợp nhiều loại dữ liệu hành vi**. Các nghiên cứu trước đây thường tập trung vào một khía cạnh cụ thể, ví dụ như hành vi xem video hoặc làm bài tập. Trong khi đó, đề tài này khai thác đồng thời ba khía cạnh: tiếp thu nội dung (video), thực hành (problem) và tương tác xã hội (comment, reply). Sự kết hợp này giúp phân tích hành vi học tập toàn diện hơn, phản ánh đầy đủ đặc điểm của người học trong môi trường trực tuyến.

Thứ ba, **so sánh hiệu quả giữa các mô hình học máy truyền thống và học sâu**. Các công trình trước đây thường sử dụng phương pháp phân cụm hoặc các mô hình đơn giản để phân loại mức độ tham gia. Đề tài này mở rộng phạm vi bằng cách áp dụng

nhiều thuật toán khác nhau, bao gồm Logistic Regression, Random Forest, SVM, KNN, XGBoost, cũng như các mô hình học sâu như Fully Connected Neural Network và LSTM. Việc so sánh này không chỉ giúp tìm ra mô hình tối ưu mà còn cung cấp cái nhìn toàn diện về ưu nhược điểm của từng phương pháp.

Cuối cùng, **hướng ứng dụng thực tiễn** của nghiên cứu là hỗ trợ giảng viên và hệ thống MOOC trong việc quản lý người học. Kết quả phân loại có thể được sử dụng để theo dõi tiến độ học tập, cá nhân hóa nội dung giảng dạy và đưa ra cảnh báo sớm đối với những học viên có nguy cơ bỏ học. Đây là một bước tiến quan trọng trong việc nâng cao chất lượng giáo dục trực tuyến, đồng thời mở ra tiềm năng phát triển các hệ thống học tập thông minh hơn trong tương lai.

Chương 3: Cơ sở lý thuyết

3.1 Mô hình truyền thống

3.1.1 Logistic Regression

Logistic Regression là mô hình tuyến tính cơ bản, thường được dùng làm baseline. Ưu điểm là tính toán nhanh, dễ triển khai và dễ giải thích tác động của từng đặc trưng hành vi học tập lên kết quả phân loại. Tuy nhiên, mô hình này giả định quan hệ tuyến tính nên khó nắm bắt các quy luật phi tuyến tính phức tạp trong dữ liệu log.

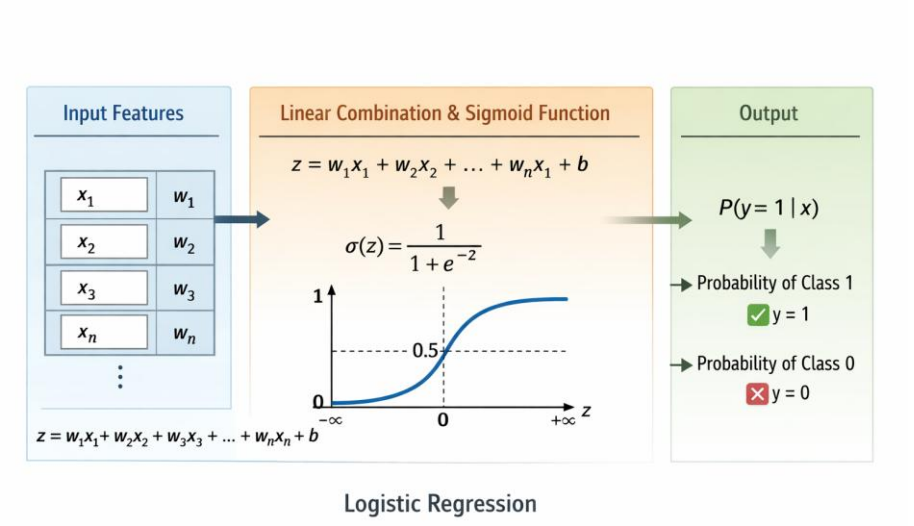

Hình 3.1 – Mô hình Logistic Regression

Sơ đồ thể hiện quá trình tính toán tuyến tính giữa các biến đầu vào x1,x2,...,xn và trọng số w1,w2,...,wn.

- **Phần trái:** các đặc trưng đầu vào (Input Features).
- **Phần giữa:** phép cộng tuyến tính z=w1x1+w2x2+...+wnxn+b được đưa qua **hàm sigmoid** σ(z)=1/(1+e−z).

Phần phải: đầu ra là xác suất P(y=1|x), biểu diễn khả năng mẫu thuộc lớp "Tương tác cao".

- → Mô hình này đóng vai trò **baseline**, giúp đánh giá tác động của từng đặc trưng hành vi lên kết quả phân loại.

3.1.2 Random Forest Classifier

Random Forest là mô hình tập hợp nhiều cây quyết định, có khả năng giảm overfitting và xử lý tốt dữ liệu nhiễu. Mô hình này còn cung cấp thông tin về mức độ quan trọng của đặc trưng (feature importance), giúp xác định yếu tố nào ảnh hưởng mạnh nhất đến mức độ tham gia học tập. Nhược điểm là có thể trở nên cồng kềnh, tốn bộ nhớ và kém nhạy bén với dữ liệu mất cân bằng nếu không xử lý kỹ.

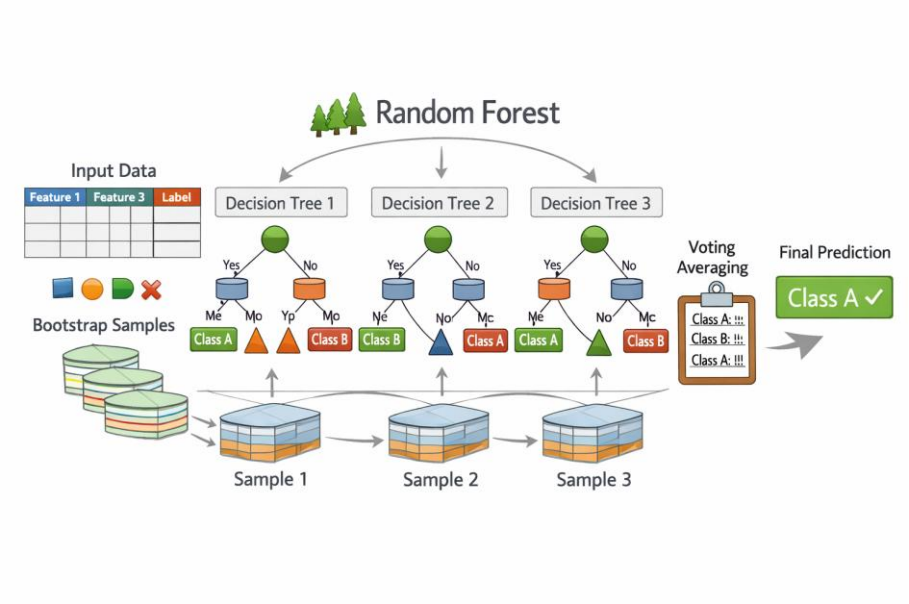

Hình 3.2 – Mô hình Random Forest

Sơ đồ minh họa tập hợp nhiều cây quyết định (Decision Trees) hoạt động song song.

- **Phần trái:** dữ liệu đầu vào được chia thành các mẫu bootstrap.
- **Phần giữa:** mỗi cây học trên một mẫu khác nhau, đưa ra dự đoán riêng.

Phần phải: kết quả cuối cùng được tổng hợp bằng **voting hoặc averaging**.

- → Random Forest giúp giảm overfitting, tăng độ ổn định và cho phép trích xuất **Feature Importance** – xác định đặc trưng hành vi nào ảnh hưởng mạnh nhất đến mức độ tham gia học tập.

3.1.3 XGBoost

XGBoost là thuật toán boosting hiện đại, nổi bật với tốc độ tính toán cao và khả năng tối ưu hóa gradient. Mô hình này hỗ trợ mạnh mẽ việc gán trọng số lớp (scale_pos_weight) để xử lý mất cân bằng dữ liệu, đồng thời tương thích tốt với kỹ thuật SMOTE. Tuy nhiên, XGBoost yêu cầu tinh chỉnh siêu tham số cẩn thận và bắt buộc phải mã hóa dữ liệu chữ sang số hoàn toàn.

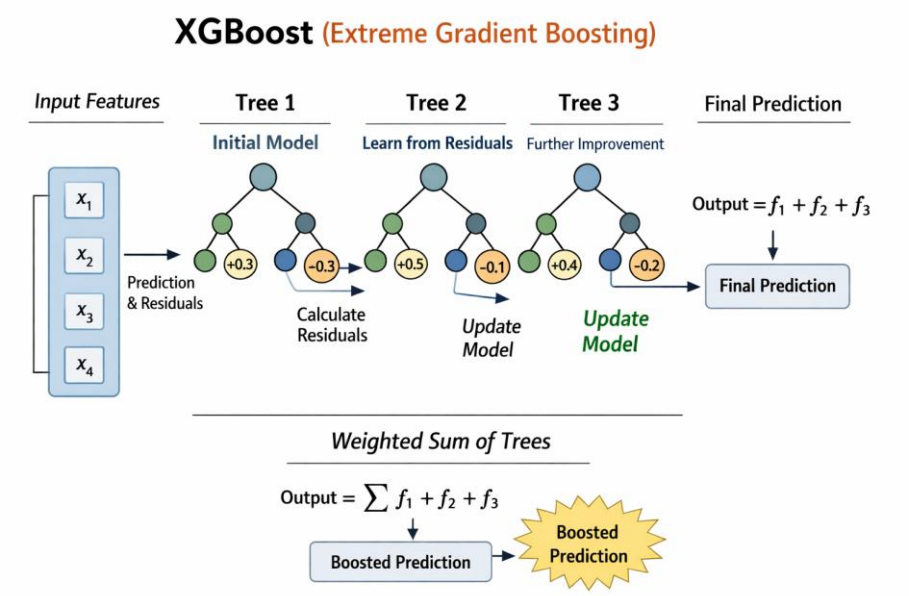

Hình 3.3 – Mô hình XGBoost

Sơ đồ mô tả quá trình **boosting tuần tự** giữa các cây nhỏ.

- **Tree 1:** mô hình ban đầu, tạo dự đoán và tính sai số (residuals).
- **Tree 2:** học từ sai số của Tree 1 để cải thiện dự đoán.
- **Tree 3:** tiếp tục tinh chỉnh để giảm lỗi còn lại.

Phần cuối: tổng hợp đầu ra của các cây theo công thức Output=f1+f2+f3.

- → XGBoost tối ưu hóa tốc độ và hiệu năng, đặc biệt phù hợp với dữ liệu lớn và mất cân bằng như MOOCCubeX.

3.1.4 CatBoost

CatBoost là một thuật toán boosting chuyên biệt cho dữ liệu dạng phân loại (categorical), có khả năng xử lý trực tiếp các biến phân loại mà không cần one-hot encoding. Mô hình này tích hợp sẵn cơ chế cân bằng lớp (auto_class_weights), tốc độ dự báo nhanh và hiệu quả cao. Nhược điểm là thời gian huấn luyện ban đầu có thể tốn kém nếu không có GPU hỗ trợ.

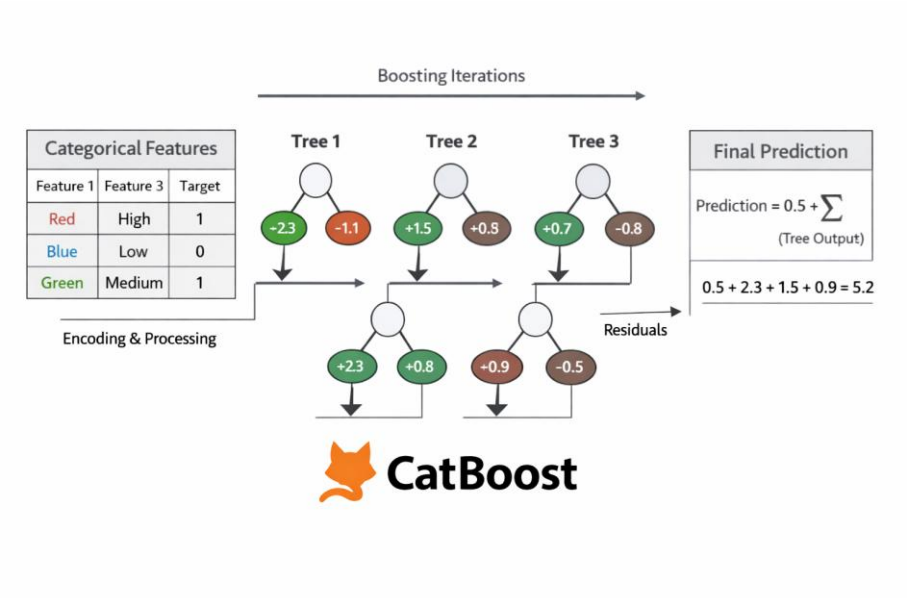

Hình 3.4 – Mô hình CatBoost

Sơ đồ thể hiện quá trình **boosting chuyên biệt cho dữ liệu dạng phân loại (categorical)**.

- **Phần trái:** bảng dữ liệu chứa các biến phân loại như màu sắc, mức độ, nhóm học viên.
- **Phần giữa:** chuỗi các cây quyết định học tuần tự từ phần dư (residuals).

Phần phải: tổng hợp đầu ra của các cây để tạo dự đoán cuối cùng.

- → CatBoost xử lý trực tiếp dữ liệu categorical mà không cần one-hot encoding, giúp giảm thời gian tiền xử lý và tăng độ chính xác.

3.2 Mô hình học sâu

3.2.1 Fully Connected Neural Network (FCNN)

FCNN là mạng nơ-ron truyền thống với nhiều lớp ẩn, có khả năng học các quan hệ phi tuyến tính giữa đặc trưng và nhãn. Mô hình này phù hợp với dữ liệu đã được tổng hợp thành vector đặc trưng, giúp mô hình hóa mối quan hệ đa chiều giữa các hành vi học tập. Tuy nhiên, FCNN yêu cầu dữ liệu đã được xử lý và chuẩn hóa tốt để đạt hiệu quả cao.

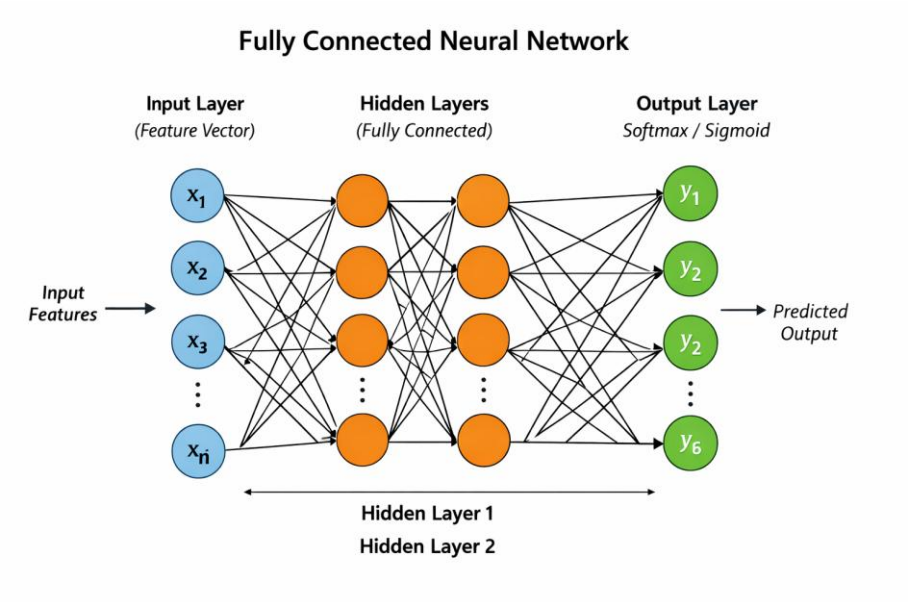

Hình 3.5 – Mô hình FCNN (Fully Connected Neural Network)

Sơ đồ mạng nơ-ron nhiều lớp:

- **Input Layer:** nhận vector đặc trưng hành vi học tập (thời gian xem video, số bài tập, số bình luận...).
- **Hidden Layers:** các lớp ẩn fully connected, mỗi neuron kết nối với toàn bộ neuron lớp trước.

Output Layer: sử dụng hàm Softmax hoặc Sigmoid để phân loại học viên thành ba nhóm tương tác.

→ FCNN giúp mô hình hóa các quan hệ phi tuyến tính phức tạp giữa các hành vi học tập.

3.2.2 Long Short-Term Memory (LSTM)

LSTM là một biến thể của mạng nơ-ron hồi tiếp (RNN), được thiết kế để xử lý dữ liệu chuỗi dài và khắc phục hiện tượng mất thông tin trong quá trình lan truyền. LSTM đặc biệt hữu ích khi phân tích dữ liệu hành vi theo tuần, vì nó có thể nắm bắt được xu hướng và sự thay đổi trong mức độ tham gia học tập của sinh viên theo thời gian. Đây là mô hình mạnh mẽ trong việc dự báo chuỗi thời gian, nhưng đòi hỏi tài nguyên tính toán lớn.

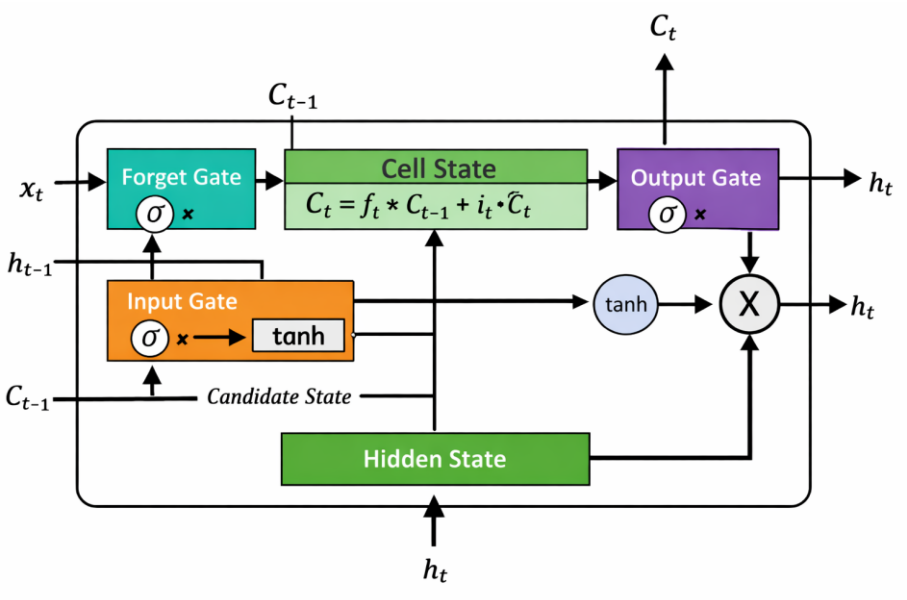

Hình 3.6 – Mô hình LSTM (Long Short-Term Memory)

Sơ đồ khối LSTM gồm các cổng: **Forget Gate**, **Input Gate**, **Output Gate**, và **Cell State**.

- **Forget Gate:** quyết định thông tin nào từ trạng thái trước cần loại bỏ.
- **Input Gate:** chọn thông tin mới cần thêm vào bộ nhớ.
- **Cell State:** lưu trữ thông tin dài hạn.

Output Gate: tạo đầu ra ht cho bước thời gian hiện tại.

- → LSTM đặc biệt phù hợp với dữ liệu chuỗi thời gian (theo tuần học), giúp mô hình dự đoán xu hướng thay đổi mức độ tham gia của học viên.

3.3 Phân cụm và gán nhãn dữ liệu

3.3.1 K-Means Clustering

K-Means được sử dụng để gán nhãn dữ liệu một cách khách quan. Sau khi chuẩn hóa dữ liệu bằng Z-score, thuật toán phân cụm theo khoảng cách Euclidean và xác định số cụm tối ưu bằng phương pháp Elbow kết hợp Silhouette Score. Ba cụm được tạo ra sẽ được gán nhãn High, Medium, Low dựa trên giá trị trung bình của các đặc trưng cốt lõi như thời lượng xem video, số lần làm bài tập và mức độ tham gia thảo luận. Đây là bước trung gian quan trọng, tạo ground-truth để huấn luyện các mô hình học có giám sát.

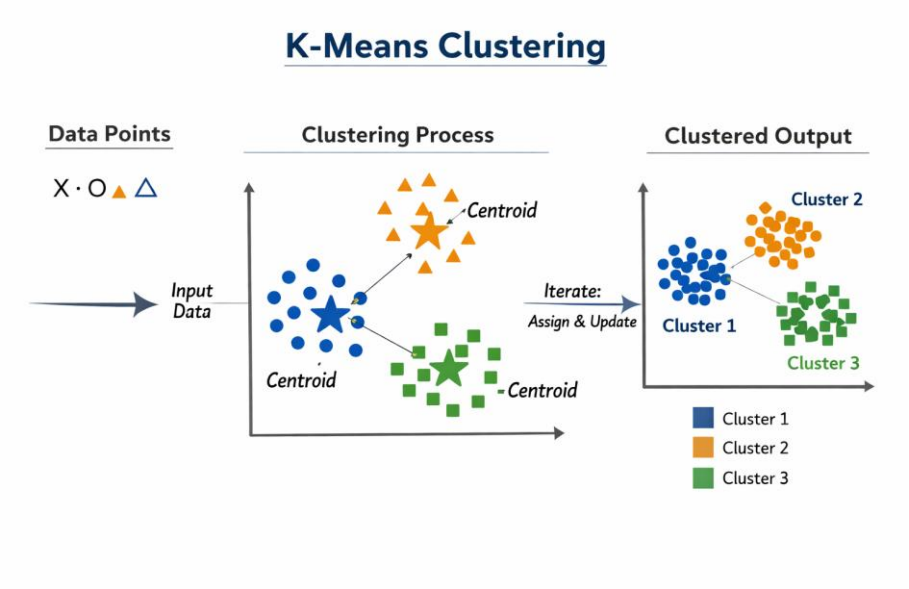

Hình 3.7 – Mô hình K-Means Clustering

Sơ đồ minh họa quá trình phân cụm dữ liệu hành vi học tập.

- **Phần trái:** dữ liệu đầu vào gồm các điểm đặc trưng (video, bài tập, bình luận).

- **Phần giữa:** thuật toán gán mỗi điểm vào cụm gần nhất dựa trên khoảng cách Euclidean, sau đó cập nhật centroid.

Phần phải: kết quả cuối cùng gồm ba cụm: **High**, **Medium**, **Low Engagement**.

- → K-Means được dùng để **gán nhãn tự động** cho dữ liệu, tạo ground-truth khách quan cho các mô hình học có giám sát.

3.4 Độ đo đánh giá

Trong bối cảnh dữ liệu mất cân bằng và bài toán phân loại đa lớp, nghiên cứu sử dụng hệ thống độ đo chi tiết:

- **Confusion Matrix**: quan sát trực quan số lượng sinh viên bị dự đoán sai, đặc biệt là các trường hợp nhầm lẫn giữa nhóm Low và High Engagement.
- **Precision – Recall**: chú trọng vào Recall của lớp Low, bởi việc bỏ sót sinh viên có nguy cơ bỏ học sẽ gây ảnh hưởng nghiêm trọng hơn so với việc dự báo nhầm một sinh viên bình thường.
- **F1-Score**: sử dụng cả Macro F1 (trung bình cộng F1 của ba nhãn, đảm bảo công bằng cho lớp Medium vốn ít mẫu) và Weighted F1 (trung bình F1 có tính đến trọng số theo số lượng mẫu của từng nhãn).
- **ROC-AUC (One-vs-Rest)**: đo lường khả năng phân tách của mô hình giữa một lớp bất kỳ với các lớp còn lại. AUC > 0.85 được xem là ngưỡng cho thấy mô hình có tính ứng dụng cao.
- **Feature Importance và SHAP values**: trích xuất từ các mô hình dạng cây như Random Forest, XGBoost và CatBoost. Đây là công cụ vừa để đánh giá toàn cục (Global Interpretability – xác định đặc trưng nào quan trọng nhất) vừa để giải thích cục bộ (Local Interpretability – lý giải tại sao một sinh viên cụ thể bị dự đoán vào nhóm Low).

Chương 4: Tìm hiểu và Khám phá dữ liệu

4.1 Giới thiệu bộ dữ liệu MOOCCubeX

MOOCCubeX là bộ dữ liệu quy mô lớn thu thập từ nền tảng XuetangX, bao gồm hơn 4.216 khóa học, 230.263 video, 358.265 bài tập, 637.572 khái niệm và hơn 296 triệu bản ghi hành vi học tập của hơn 3,3 triệu học viên. Trong nghiên cứu này, nhóm tập trung vào 5 bảng dữ liệu chính: **user.json, user-video.json, user-problem.json, comment.json, reply.json**. Đây là những bảng phản ánh ba khía cạnh quan trọng: tiếp thu nội dung (video), thực hành (problem) và tương tác xã hội (comment, reply).

4.2 Khám phá tập dữ liệu user.json

- **Quy mô**: 719.557 bản ghi, 7 thuộc tính.
- **Cấu trúc**: id, name, gender, school, year_of_birth, course_order, enroll_time.
- **Phân bố**: gender mã hóa từ 0–2, đầy đủ dữ liệu; year_of_birth có tới 701.082 giá trị thiếu (≈97%).
- **Nhận xét**: dữ liệu khá sạch, ngoại trừ cột year_of_birth. Các thông tin về trường học và thời gian đăng ký hữu ích cho phân tích hành vi học tập.

4.3 Khám phá tập dữ liệu user-problem.json

- **Quy mô**: 1.000.000 bản ghi, 7 thuộc tính.
- **Cấu trúc**: log_id, problem_id, user_id, is_correct, attempts, score, submit_time.
- **Phân bố**:
  - is_correct trung bình ≈ 0.82 → phần lớn câu hỏi được trả lời đúng.
  - attempts trung bình ≈ 1.06, nhưng có outlier tới 121 lần thử.
  - score trung bình ≈ 1.51, tồn tại giá trị âm và nhiều bản ghi thiếu (≈48%).
- **Nhận xét**: dữ liệu phản ánh rõ hành vi làm bài, song cần xử lý score bị thiếu và outlier ở attempts.

4.3 Khám phá tập dữ liệu user-video.json

- **Quy mô**: 25.572 bản ghi, 2 thuộc tính (user_id, seq).

- **Cấu trúc**: seq chứa danh sách video và các đoạn thời gian xem (segment).
- **Phân bố**: mỗi video có thể được xem nhiều lần, thể hiện hành vi tua lại hoặc xem lại.
- **Nhận xét**: dữ liệu không có giá trị thiếu, nhưng cấu trúc phức tạp (nested JSON) nên cần làm phẳng để trích xuất đặc trưng như tổng thời gian xem, số video duy nhất đã xem, số lần xem lại.

4.4 Khám phá tập dữ liệu comment.json

- **Quy mô**: hơn 8,4 triệu bản ghi.
- **Cấu trúc**: id, user_id, text, create_time, resource_id.
- **Phân bố**: nội dung bình luận phong phú, gắn với video hoặc bài tập cụ thể. Một số bản ghi có resource_id null.
- **Nhận xét**: dữ liệu lớn, phản ánh mức độ tham gia thảo luận, có thể kết hợp với reply để đánh giá toàn diện hành vi tương tác xã hội.

4.5 Khám phá tập dữ liệu reply.json

- **Quy mô**: 331.011 bản ghi, 4 thuộc tính (id, user_id, text, create_time).
- **Phân bố**: có 50.313 người dùng tham gia phản hồi, một số người dùng có số lượng phản hồi rất cao (tới 22.477). Nội dung phản hồi đa dạng với hơn 148.000 câu khác nhau, nhưng có một số câu phổ biến xuất hiện nhiều lần.
- **Nhận xét**: dữ liệu sạch, không có giá trị thiếu, phản ánh rõ mức độ tương tác xã hội và tính chủ động của người học.

4.6. Quá trình tổng hợp dữ liệu

Sau khi kết hợp năm tập dữ liệu chính thành một tập dữ liệu quy mô lớn phục vụ phân tích hành vi người học trong môi trường MOOC . Bộ dữ liệu bao gồm năm bảng dữ liệu dị thể, phản ánh các khía cạnh khác nhau của người học, cụ thể:

- Bảng *user*: chứa thông tin hồ sơ người học (định danh, nhân khẩu học và lịch sử đăng ký khóa học), đóng vai trò là dữ liệu nền (*static features*).
- Bảng *user-problem*: ghi nhận các tương tác với bài tập như kết quả, số lần thử và điểm số, phản ánh hiệu suất học tập.

- Bảng *user-video*: lưu trữ hành vi xem video, thể hiện mức độ tham gia học tập (*learning engagement*).
- Bảng *comment*: chứa các bình luận của người học trên tài nguyên học tập, phản ánh tương tác nội dung.
- Bảng *reply*: ghi nhận các phản hồi trong thảo luận, thể hiện tương tác xã hội giữa người học.

Trước khi tích hợp, dữ liệu được tiền xử lý bằng cách áp dụng bước lọc có điều kiện, trong đó chỉ giữ lại các người dùng đăng ký từ 5 khóa học trở lên nhằm đảm bảo mức độ tham gia tối thiểu. Sau bước này, tập dữ liệu người dùng thu được gồm 129.516 bản ghi × 8 thuộc tính, đóng vai trò là bảng trung tâm trong quá trình tích hợp.

Quá trình tích hợp dữ liệu được thực hiện theo chiến lược tích hợp tuần tự, sử dụng phép nối trái (*left outer join*) trên khóa user_id. Phương pháp này đảm bảo bảo toàn toàn bộ tập người dùng ban đầu, đồng thời bổ sung thông tin từ các bảng hành vi khi tồn tại liên kết tương ứng .

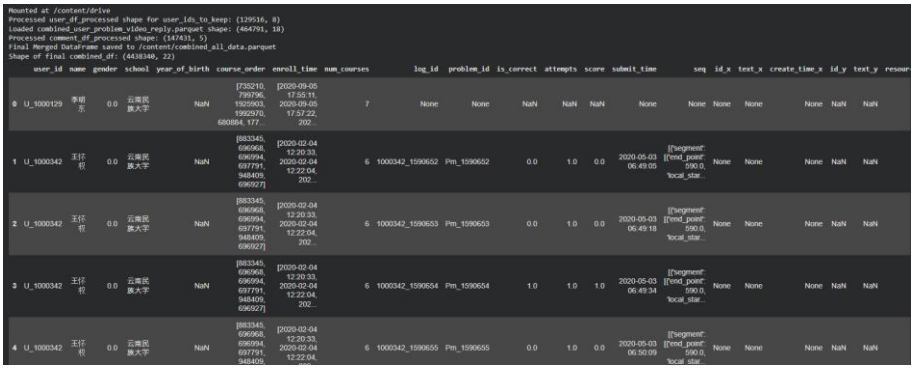

```
Mounted at /content/drive
Processed user_df_processed shape for user_ids_to_keep: (129516, 8)
Loaded combined_user_problem_video_reply.parquet shape: (464791, 18)
Processed comment_df_processed shape: (147431, 5)
Final Merged DataFrame saved to /content/combined_all_data.parquet
Shape of final combined_df: (4438340, 22)
```

	user_id	name	gender	school	year_of_birth	course_order	enroll_time	num_courses	log_id	problem_id	is_correct	attempts	score	submit_time	seq	id_x	text_x	create_time_x	id_y	text_y	resour
0	U_1000129	李明东	0.0	云南民族大学	NaN	[735210, 799796, 1925903, 1992970, 680884, 177...	[2020-09-05 17:55:11, 2020-09-05 17:57:22, 202...	7	None	None	NaN	NaN	NaN	None	None	None	None	None	NaN	NaN	
1	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6	1000342_1590652	Pm_1590652	0.0	1.0	0.0	2020-05-03 06:48:05	[{"segment": [{"end_point": 590.0, "local_star...	None	None	None	NaN	NaN	
2	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6	1000342_1590653	Pm_1590653	0.0	1.0	0.0	2020-05-03 06:49:18	[{"segment": [{"end_point": 590.0, "local_star...	None	None	None	NaN	NaN	
3	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6	1000342_1590654	Pm_1590654	1.0	1.0	1.0	2020-05-03 06:49:34	[{"segment": [{"end_point": 590.0, "local_star...	None	None	None	NaN	NaN	
4	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409	[2020-02-04 12:20:33, 2020-02-04 12:22:04,	6	1000342_1590655	Pm_1590655	0.0	1.0	0.0	2020-05-03 06:50:09	[{"segment": [{"end_point": 590.0, "local_star...	None	None	None	NaN	NaN	

Hình 4.1 – Hình dữ liệu sau khi tổng hợp

Cụ thể, các bảng *user-problem*, *user-video* và *reply* được kết hợp trước, tạo thành tập dữ liệu trung gian với kích thước 464.791 bản ghi × 18 thuộc tính. Sau đó, bảng *comment* tiếp tục được tích hợp để hình thành tập dữ liệu cuối cùng.

Kết quả, tập dữ liệu tổng hợp đạt kích thước **4.438.340 bản ghi × 22 thuộc tính**.

Mô tả các thuộc tính trong tập dữ liệu

Tập dữ liệu sau khi tích hợp bao gồm 22 thuộc tính, được chia thành các nhóm đặc trưng chính như sau:

a. Nhóm đặc trưng hồ sơ (User Profile Features)

	user_id	name	gender	school	year_of_birth	course_order	enroll_time	num_courses
0	U_1000129	李明东	0.0	云南民族大学	NaN	[735210, 799796, 1925903, 1992970, 680884, 177...	[2020-09-05 17:55:11, 2020-09-05 17:57:22, 202...	7
1	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6
2	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6
3	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6
4	U_1000342	王怀权	0.0	云南民族大学	NaN	[883345, 696968, 696994, 697791, 948409, 696927]	[2020-02-04 12:20:33, 2020-02-04 12:22:04, 202...	6

Hình 4.2 – Các thuộc tính tĩnh

- *user_id*: Mã định danh người dùng
- *name*: Tên người dùng
- *gender*: Giới tính
- *school*: Trường học
- *year_of_birth*: Năm sinh
- *course_order*: Danh sách khóa học đã đăng ký
- *enroll_time*: Thời điểm đăng ký khóa học
- *num_courses*: Số lượng khóa học đã tham gia

b. Nhóm đặc trưng hành vi học tập (Learning Behavior Features)

log_id	problem_id	is_correct	attempts	score	submit_time	seq
None	None	NaN	NaN	NaN	None	None
1000342_1590652	Pm_1590652	0.0	1.0	0.0	2020-05-03 06:49:05	[{'segment': [{'end_point': 590.0, 'local_star...
1000342_1590653	Pm_1590653	0.0	1.0	0.0	2020-05-03 06:49:18	[{'segment': [{'end_point': 590.0, 'local_star...
1000342_1590654	Pm_1590654	1.0	1.0	1.0	2020-05-03 06:49:34	[{'segment': [{'end_point': 590.0, 'local_star...
1000342_1590655	Pm_1590655	0.0	1.0	0.0	2020-05-03 06:50:09	[{'segment': [{'end_point': 590.0, 'local_star...

Hình 4.3 – Các thuộc tính động 1

- *log_id*: Mã lần làm bài
- *problem_id*: Mã bài tập
- *is_correct*: Kết quả làm bài
- *attempts*: Số lần thử
- *score*: Điểm số
- *submit_time*: Thời điểm nộp bài
- *seq*: Thông tin chi tiết quá trình làm bài hoặc xem video

Trong đó, thuộc tính seq là một trong những đặc trưng chính phản ánh hành vi xem video của người học. Dữ liệu *user-video* trong MOOCCubeX được ghi nhận theo dạng chuỗi tương tác video có cấu trúc phức hợp, trong đó mỗi phần tử của seq mô tả chi tiết các phiên xem video bởi một người dùng .

Cụ thể, mỗi bản ghi trong cột seq là một danh sách các đối tượng JSON, mỗi đối tượng đại diện cho tương tác của một người dùng với một video cụ thể. Trong đó:

- video_id là định danh của video mà người dùng đã xem;
- segment là danh sách các đoạn xem video, với từng segment bao gồm:
    - start_point: thời điểm bắt đầu segment trong video
    - end_point: thời điểm kết thúc segment trong video

Cấu trúc này cho phép lưu trữ toàn bộ quá trình tương tác video ở mức độ chi tiết nhất, bao gồm tất cả các phiên xem và các hành vi phụ như tua, tạm dừng hoặc xem lại các đoạn nội dung cụ thể. Do đó, seq thể hiện dữ liệu ở dạng chuỗi hành vi tuần tự (*sequential interaction data*), một mô hình biểu diễn tiêu chuẩn trong phân tích hành vi người học và khai phá dữ liệu giáo dục.

Để phục vụ phân tích và mô hình hóa, seq được sẽ được chuyển đổi thêm cụ thể sang dạng bảng bằng cách:

1. Làm phẳng chuỗi hành vi để trích xuất:
    - user_id, video_id, và watch_time (thời gian xem mỗi đoạn).
2. Tổng hợp theo người dùng thành các đặc trưng:
    - video_watch_count – tổng số phân đoạn xem video,
    - total_watch_time – tổng thời gian xem,
    - unique_videos – số video khác nhau đã xem.

user_id	video_watch_count	total_watch_time	unique_videos
U_10001181	37	2878.000	1
U_10001587	28	8180.300	4
U_1000290	16	2311.700	4
U_1000342	12	60.000	2
U_1000454	2	495.119	2

Hình 4.4 – Các thuộc tính động 2

Các đặc trưng này phản ánh mức độ tương tác video của mỗi người học và là tiền đề cho các phân tích hành vi tiếp theo.

c. Nhóm đặc trưng tương tác xã hội (Social Interaction Features)

id_x	text_x	create_time_x	id_y	text_y	resource_id	create_time_y
None	None	None	NaN	NaN	NaN	NaN
None	None	None	NaN	NaN	NaN	NaN
None	None	None	NaN	NaN	NaN	NaN
None	None	None	NaN	NaN	NaN	NaN
None	None	None	NaN	NaN	NaN	NaN

Hình 4.5 – Các thuộc tính động 3

- *id_x, text_x, create_time_x*: thông tin phản hồi (*reply*)
- *id_y, text_y, resource_id, create_time_y*: thông tin bình luận (*comment*)

Tóm lại, các thuộc tính trong tập dữ liệu có thể được phân thành hai loại chính:

- Đặc trưng tĩnh (static features): bao gồm thông tin hồ sơ người dùng
- Đặc trưng động (behavioral features): bao gồm dữ liệu hành vi học tập và tương tác

Sự kết hợp giữa hai nhóm đặc trưng này tạo thành một không gian dữ liệu đa chiều, cho phép khai thác hiệu quả trong các bài toán như phân tích hành vi người học từ đó dự đoán được loại học sinh trên nền tảng học online này.

4.7 Khám phá dữ liệu tổng quan

Quá trình **Exploratory Data Analysis (EDA)** được tiến hành nhằm khảo sát cấu trúc, kiểm tra dữ liệu thiếu, phát hiện outlier và đánh giá phân bố của các biến số. Một số kết quả quan trọng:

- **Quy mô và cấu trúc**: dữ liệu có hàng trăm nghìn đến hàng triệu bản ghi, dung lượng lớn (tới hàng chục GB). Các bảng dữ liệu chủ yếu ở dạng log sự kiện (event data), mỗi bản ghi phản ánh một hành động cụ thể của người học.
- **Dữ liệu thiếu**:
    - Trong **user.json**, thuộc tính *year_of_birth* có tới 97% giá trị bị thiếu, cho thấy thông tin nhân khẩu học không đầy đủ.
    - Trong **user-problem.json**, thuộc tính *score* chỉ có dữ liệu ở khoảng 52% bản ghi, phần còn lại bị thiếu.
- **Outlier và phân bố bất thường**:
    - Trong **user-problem.json**, biến *attempts* có giá trị cực đại tới 121 lần thử, phản ánh hành vi bất thường.
    - Biến *score* có giá trị âm (-1), cho thấy dữ liệu đặc biệt hoặc lỗi ghi nhận.
- **Hành vi xem video**: dữ liệu **user-video.json** cho thấy nhiều học viên có hành vi tua lại, xem lại nhiều lần, phản ánh mức độ tham gia không chỉ đo bằng số lượng video mà còn bằng cách thức tương tác với nội dung.
- **Tương tác xã hội**: dữ liệu **comment.json** và **reply.json** cho thấy sự phân hóa rõ rệt. Một số học viên có số lượng phản hồi rất cao (hơn 20.000), trong khi phần lớn chỉ tham gia ở mức hạn chế. Nội dung phản hồi đa dạng, nhưng tồn tại nhiều câu lặp lại, phản ánh hành vi tương tác theo mẫu.

4.8 Tri thức rút ra từ quá trình khám phá

Từ EDA, có thể rút ra một số tri thức quan trọng:

1. **Mức độ tham gia học tập là biến ẩn**, không thể quan sát trực tiếp mà phải được suy luận từ hành vi thực tế.

2. **Dữ liệu hành vi học tập có tính đa chiều**, kết hợp giữa đặc trưng tĩnh (hồ sơ người học) và đặc trưng động (hành vi theo thời gian).

3. **Sự mất cân bằng lớp** là hiện tượng phổ biến: số lượng học viên có mức độ tham gia thấp thường nhiều hơn nhóm trung bình hoặc cao. Đây là thách thức cần giải quyết bằng các kỹ thuật cân bằng dữ liệu.

4. **Sự tồn tại của outlier và dữ liệu thiếu** cho thấy cần có bước tiền xử lý kỹ lưỡng để đảm bảo chất lượng dữ liệu đầu vào cho mô hình.

5. **Hành vi xã hội** (comment, reply) là yếu tố quan trọng để phân loại mức độ tham gia, bổ sung cho dữ liệu học tập truyền thống (video, problem).

4.9 Gợi mở tiền đề cho phương pháp đề xuất

Những kết quả khám phá dữ liệu này đặt nền tảng cho phương pháp nghiên cứu:

- Việc phát hiện dữ liệu thiếu và mất cân bằng lớp định hướng cho các bước **tiền xử lý** và **cân bằng dữ liệu** bằng kỹ thuật SMOTE.

- Sự đa chiều và chuỗi thời gian của dữ liệu gợi mở việc sử dụng **mô hình học sâu (LSTM)** để nắm bắt xu hướng hành vi theo tuần.

- Sự phân hóa rõ rệt về mức độ tham gia xã hội củng cố cho chiến lược **gán nhãn bằng K-Means** và **Weighted Engagement Score**, nhằm xây dựng ground-truth khách quan.

- Các đặc trưng hành vi được rút ra từ EDA sẽ là đầu vào quan trọng cho pipeline phân tích và huấn luyện mô hình phân loại học viên theo mức độ tham gia.

Chương 5: Phương pháp đề xuất

Phương pháp đề xuất được xây dựng theo hướng **Hybrid Machine Learning Pipeline**, kết hợp giữa học không giám sát (K-Means) để tạo nhãn khách quan và học có giám sát (Logistic Regression, Random Forest, XGBoost, CatBoost) để dự đoán mức độ tham gia học tập. Toàn bộ quy trình được triển khai trên nền tảng dữ liệu lớn (Big Data Framework) nhằm đảm bảo khả năng mở rộng, tự động hóa và tính ứng dụng thực tiễn.

5.1 Tổng quan quy trình

Quy trình gồm **6 giai đoạn chính**, được thể hiện trong sơ đồ tổng thể dưới đây:

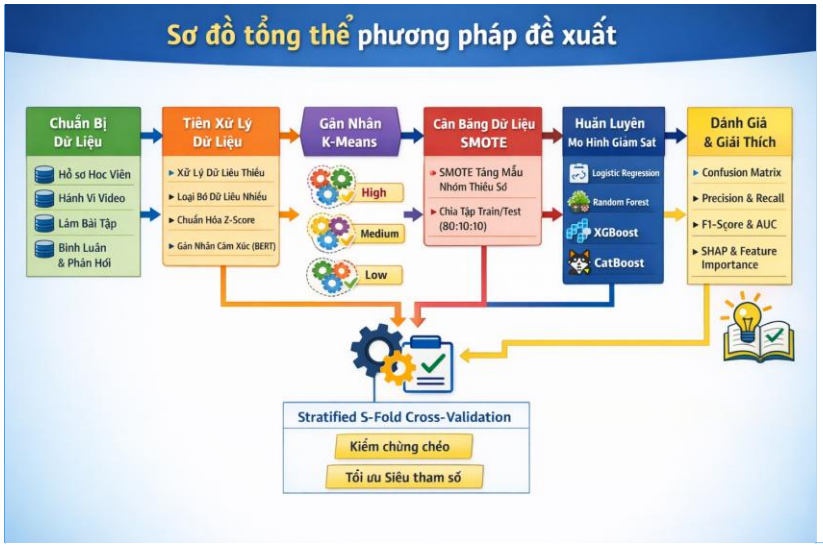

Hình 5.1 - Sơ đồ tổng thể phương pháp đề xuất – pipeline từ dữ liệu đầu vào đến đánh giá mô hình

1. **Chuẩn bị dữ liệu**

   - Thu thập dữ liệu từ 5 bảng chính của MOOCCubeX: *user, user-video, user-problem, comment, reply*.
   - Mỗi bảng phản ánh một khía cạnh hành vi học tập: hồ sơ cá nhân, hành vi xem video, làm bài tập, và tương tác xã hội.

Commented [1]: Sửa lại mô hình, không dùng kmean

2. **Tiền xử lý dữ liệu**

   - Làm sạch dữ liệu: loại bỏ bản ghi thiếu thông tin (*year_of_birth, score, resource_id*), xử lý trùng lặp và nhiễu.
   - Chuẩn hóa dữ liệu bằng **Z-score** để đồng nhất thang đo giữa các đặc trưng.
   - Dịch và gán nhãn cảm xúc cho bình luận bằng mô hình ngôn ngữ **BERT**, phân loại thành *Positive, Neutral, Negative*.
   - Kết quả là tập dữ liệu sạch, đồng nhất, sẵn sàng cho bước gán nhãn.

3. **Gán nhãn dữ liệu**

   - Áp dụng công thức tính WES cho mỗi học viên và phân cụm hành vi học tập thành 3 nhóm: *High, Medium, Low Engagement*.

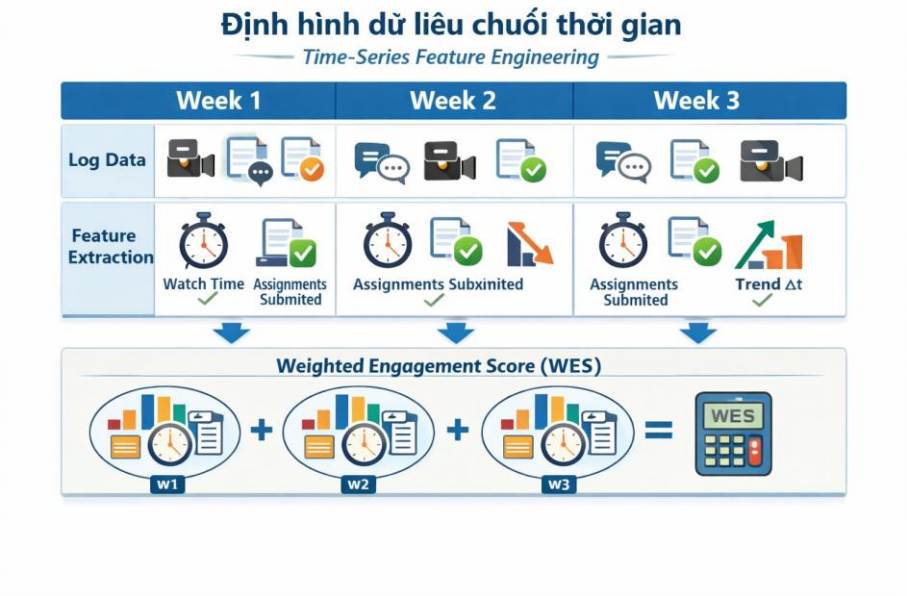

Hình 5.3 - Time series

   - Xác định số cụm tối ưu bằng phương pháp **Elbow** và **Silhouette Score**.
   - Gán nhãn dựa trên centroid của cụm, đảm bảo tính khách quan và loại bỏ yếu tố chủ quan trong đánh giá.

- Kết quả là bộ dữ liệu có nhãn chuẩn (Ground Truth) cho các mô hình học có giám sát.

4. **Xử lý mất cân bằng dữ liệu bằng SMOTE**

Commented [2]: có thể bỏ đoạn này luôn, vì ko cần thiết smote, dữ liệu 1:1:1 theo phân vị rồi

- Dữ liệu thực tế có tỷ lệ nhãn 4.8 : 1.8 : 3.5, gây mất cân bằng nghiêm trọng.
- Áp dụng **Stratified Split** để chia dữ liệu theo tỷ lệ 80:10:10 (train, validation, test).
- Thực hiện **SMOTE (Synthetic Minority Over-sampling Technique)** trên tập train để tạo mẫu nhân tạo cho nhóm thiểu số, cân bằng tỷ lệ 1:1:1.
- Giữ nguyên tập test để phản ánh đúng hiệu suất thực tế khi triển khai.

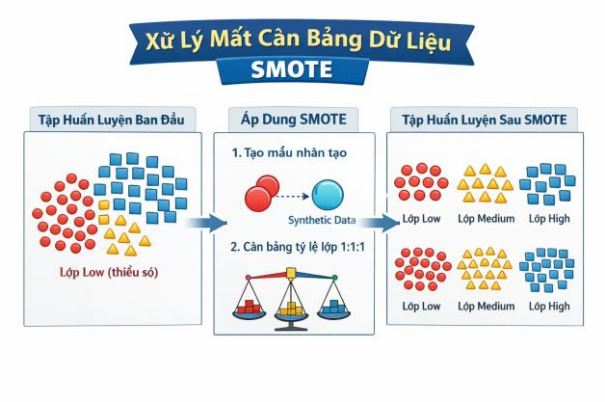

Hình 5.3 - SMOTE

5. **Huấn luyện và tối ưu mô hình học có giám sát**

- Sử dụng 5 mô hình chính:
  - **Logistic Regression**: baseline tuyến tính, dễ diễn giải.
  - **Random Forest**: giảm overfitting, trích xuất Feature Importance.
  - **XGBoost**: tối ưu gradient, xử lý dữ liệu lớn và mất cân bằng.

        - **Linear SVC**: Tối ưu hóa phân chia không gian để tìm siêu mặt phẳng ranh giới giữa các lớp tương tác, xử lý tốt trên không gian đặc trưng sau khi cân bằng.
        - **Decision Tree**: Trực quan hóa logic phân lớp rõ ràng dựa trên các đặc trưng hành vi 4 tuần đầu.
    - Áp dụng **Stratified 5-Fold Cross-Validation** để đảm bảo tính ổn định và tránh overfitting.
    - Tối ưu siêu tham số bằng **GridSearchCV** hoặc **Optuna**, đảm bảo mô hình đạt hiệu suất cao nhất.

6. **Đánh giá và giải thích mô hình**

    - **Đánh giá định lượng**:
        - *Confusion Matrix*: quan sát lỗi nhầm lẫn giữa các lớp.
        - *Precision – Recall*: ưu tiên Recall của lớp Low để tránh bỏ sót học viên có nguy cơ bỏ học.
        - *Macro F1 và Weighted F1*: đảm bảo công bằng cho lớp Medium.
        - *ROC-AUC (One-vs-Rest)*: đo lường khả năng phân tách giữa các lớp.
    - **Giải thích mô hình (Model Interpretability)**:
        - *Feature Importance*: xác định đặc trưng ảnh hưởng mạnh nhất (ví dụ: delta_watch_time).
        - *SHAP Values*: giải thích cục bộ cho từng học viên, chuyển đổi kết quả toán học thành tri thức nghiệp vụ.
        - Giảng viên có thể dựa vào biểu đồ SHAP để hiểu nguyên nhân dự báo và đưa ra hành động phù hợp.

5.2 Mối liên hệ giữa các giai đoạn

Các giai đoạn trong pipeline không hoạt động độc lập mà liên kết chặt chẽ theo chuỗi:

- **Dữ liệu đầu vào** (user, video, problem, comment, reply) →**Tiền xử lý** (làm sạch, chuẩn hóa, gán nhãn cảm xúc) **→ Gán nhãn** → **Cân bằng dữ liệu**

(SMOTE) →
Huấn luyện mô hình (Supervised Learning) → **Đánh giá & Giải thích** (Metrics + SHAP).

Mỗi giai đoạn tạo ra đầu ra (output) là đầu vào (input) cho giai đoạn kế tiếp, đảm bảo luồng dữ liệu liên tục và có thể mở rộng.

Chương 6: Kiến trúc Data Engineering Pipeline trên AWS

6.1 Giới thiệu

Trong bối cảnh dữ liệu giáo dục trực tuyến ngày càng trở nên phức tạp, việc xây dựng một hệ thống xử lý dữ liệu tự động, có khả năng mở rộng và đảm bảo tính minh bạch là yêu cầu tất yếu của các nghiên cứu về **Educational Data Mining (EDM)** và **Learning Analytics (LA)**.

Đề tài này triển khai **kiến trúc Data Engineering Pipeline** trên nền tảng **Amazon Web Services (AWS)** nhằm tối ưu hóa quy trình thu thập, xử lý, gắn nhãn và phân tích dữ liệu hành vi học tập của học viên trong hệ sinh thái MOOC.

Pipeline được thiết kế theo mô hình **Raw → Processing → Catalog → AI → BI**, đảm bảo tính liên tục của luồng dữ liệu, khả năng tích hợp giữa các tầng dịch vụ, và hỗ trợ phân tích học viên theo hướng **Adaptive Learning**.

6.2 Kiến trúc tổng thể của Pipeline

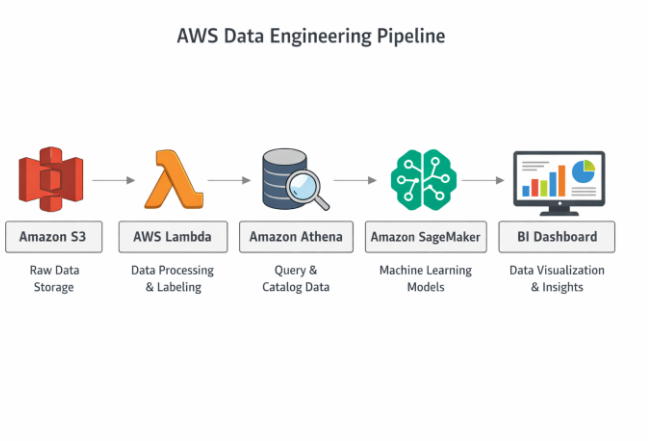

Hình 6.1: Sơ đồ AWS Data Engineering Pipeline – gồm các tầng S3, Lambda, Athena, SageMaker và Dashboard BI.

Pipeline gồm năm tầng chính, mỗi tầng đảm nhiệm một vai trò cụ thể trong chuỗi giá trị dữ liệu. Các tầng được kết nối bằng cơ chế trigger và API nội bộ của AWS, đảm bảo tính tự động hóa và khả năng mở rộng.

(1) Amazon S3 – Tầng lưu trữ dữ liệu thô (Raw Data Storage)

Vai trò:

Amazon S3 đóng vai trò là **Data Lake** của hệ thống, nơi lưu trữ toàn bộ dữ liệu thô từ các nguồn khác nhau: user, user-problem, user-video, comment, và course. Các bảng này được hợp nhất thành file **combined_all_data.parquet** để tối ưu hóa tốc độ truy xuất và giảm dung lượng lưu trữ.

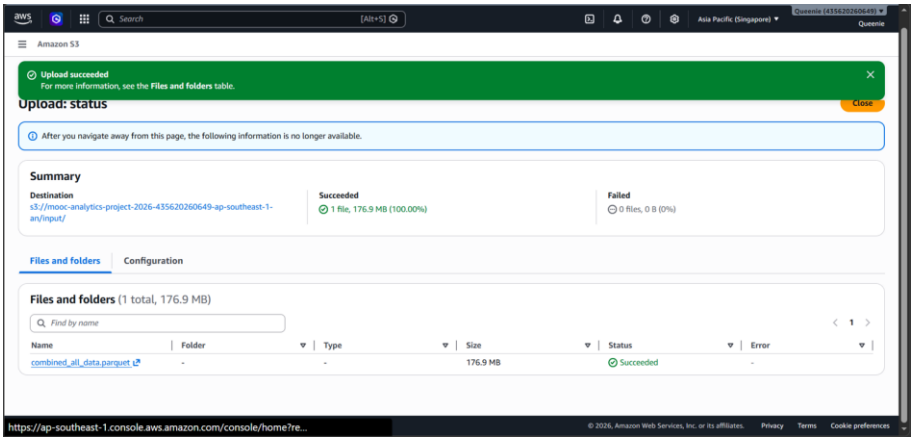

Hình 6.2 - Triển khai S3 lưu dữ liệu

Lý do lựa chọn:

- S3 cung cấp khả năng lưu trữ phi cấu trúc với chi phí thấp và độ tin cậy cao.
- Tích hợp trực tiếp với các dịch vụ AWS khác như Lambda, Athena, và SageMaker.
- Hỗ trợ định dạng Parquet giúp giảm dung lượng và tăng tốc độ đọc dữ liệu.

Ý nghĩa với đề tài:

S3 đảm bảo dữ liệu gốc được bảo toàn, phục vụ cho việc tái lập mô hình hoặc kiểm chứng kết quả. Đây là nền tảng cho mọi hoạt động xử lý và phân tích sau này.

(Hình minh họa: Upload file thành công lên S3, dung lượng 176.9 MB)

(2) AWS Lambda – Tầng xử lý và gắn nhãn sơ bộ (Processing & Labeling)

Vai trò:

Lambda function **Mooc-Data-Processor** được thiết kế để tự động kích hoạt khi có dữ liệu mới trên S3. Đây là tầng **ETL (Extract – Transform – Load)** của pipeline, chịu trách nhiệm tiền xử lý và gắn nhãn sơ bộ cho dữ liệu.

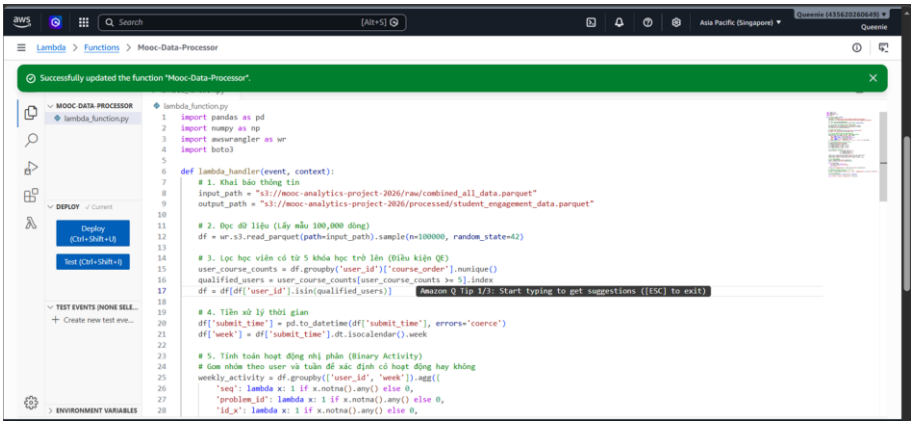

Hình 6.3: Code deploy Lambda để làm sạch và tính toán dữ liệu lấy từ S3.

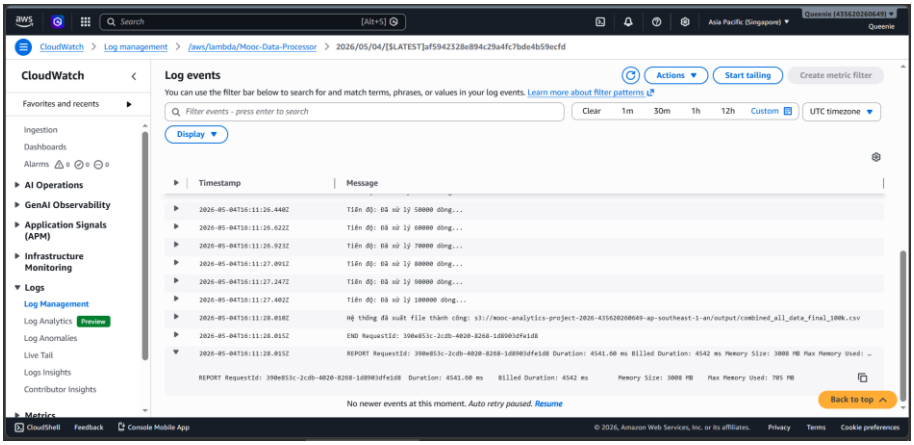

Hình 6.4: CloudWatch để theo dõi log quá trình code trigger dữ liệu.

Quy trình xử lý:

- Lọc học viên đủ điều kiện (≥ 5 khóa học).
- Chuẩn hóa timestamp, tính toán hoạt động theo tuần.
- Tính toán **Weighted Engagement Score (WES)** dựa trên tần suất hoạt động, thời gian xem video và số bài tập hoàn thành.

- Gắn nhãn sơ bộ theo phân vị (quantile labeling).
- Ghi kết quả xử lý trở lại S3 để phục vụ cho Athena.

Lý do lựa chọn:

- Lambda cho phép thực thi code mà không cần quản lý server (serverless).
- Tự động trigger khi có thay đổi trong bucket S3.
- Tích hợp với CloudWatch để giám sát log và hiệu năng.

Ý nghĩa với đề tài:

Lambda giúp tự động hóa toàn bộ quy trình xử lý dữ liệu, giảm thiểu sai sót thủ công và đảm bảo tính nhất quán trong việc tính toán chỉ số tương tác học viên.

(Hình minh họa: Lambda function với code xử lý dữ liệu và tính toán chỉ số)

(3) Amazon Athena – Tầng catalog và truy vấn dữ liệu (Query & Catalog Data)

Vai trò:

Athena đóng vai trò là **Data Catalog** và **Query Engine** cho dữ liệu đã xử lý. Sau khi Lambda hoàn tất, dữ liệu được lưu lại trên S3 và Athena tạo bảng metadata để truy vấn trực tiếp bằng SQL.

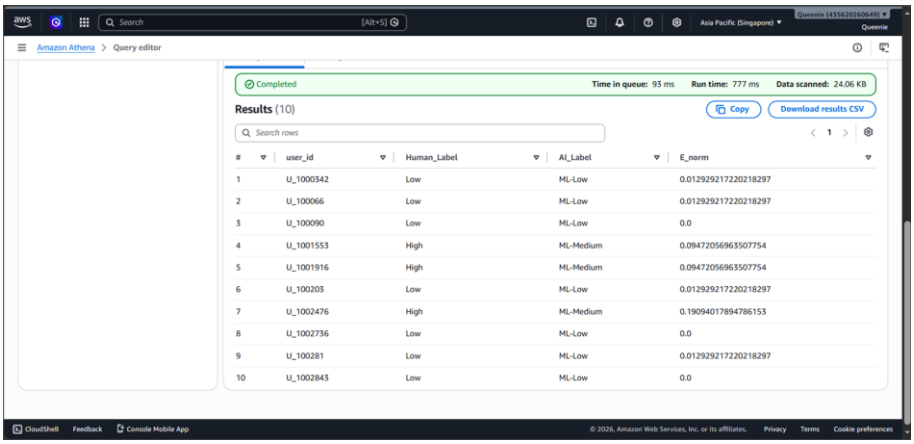

Hình 6.5: CloudWatch để theo dõi log quá trình code trigger dữ liệu.

Quy trình:

- Định nghĩa schema bằng Glue Data Catalog.
- Truy vấn dữ liệu Parquet trực tiếp từ S3.
- So sánh nhãn **Human_Label** và **AI_Label** để đánh giá độ chính xác của mô hình.

Lý do lựa chọn:

- Athena cho phép truy vấn dữ liệu lớn mà không cần thiết lập hạ tầng phức tạp.
- Tích hợp tự nhiên với S3, hỗ trợ định dạng Parquet và ORC.
- Chi phí tính theo lượng dữ liệu quét, phù hợp với nghiên cứu học thuật.

Ý nghĩa với đề tài:

Athena giúp kiểm chứng kết quả gắn nhãn, đánh giá độ chính xác của mô hình AI, và cung cấp dữ liệu đầu vào cho tầng BI.

(Hình minh họa: Athena Query Editor hiển thị kết quả so sánh nhãn Human_Label và AI_Label)

(4) Amazon SageMaker – Tầng huấn luyện AI/ML (Machine Learning Models)

Vai trò:

SageMaker là trung tâm huấn luyện và triển khai mô hình học máy trong pipeline. Tại đây, dữ liệu từ Athena được sử dụng để huấn luyện mô hình **K-Means Clustering**, nhằm gán nhãn khách quan cho học viên.

Quy trình:

- Chuẩn hóa dữ liệu bằng StandardScaler.
- Áp dụng K-Means để phân cụm hành vi học tập thành 3 nhóm: High, Medium, Low.
- So sánh kết quả với nhãn phân vị gán trước đó.
- Lưu kết quả gắn nhãn AI vào Athena để phục vụ phân tích sau.

Lý do lựa chọn:

- SageMaker cung cấp môi trường notebook tích hợp, hỗ trợ scikit-learn, TensorFlow, PyTorch.
- Cho phép kết nối trực tiếp với S3 và Athena.
- Hỗ trợ triển khai mô hình nhanh chóng và mở rộng quy mô huấn luyện.

Ý nghĩa với đề tài:

SageMaker giúp loại bỏ yếu tố chủ quan trong gán nhãn, đồng thời tạo nền tảng cho việc phát triển các mô hình dự đoán nâng cao như **Dropout Prediction** hoặc **Engagement Forecasting**.

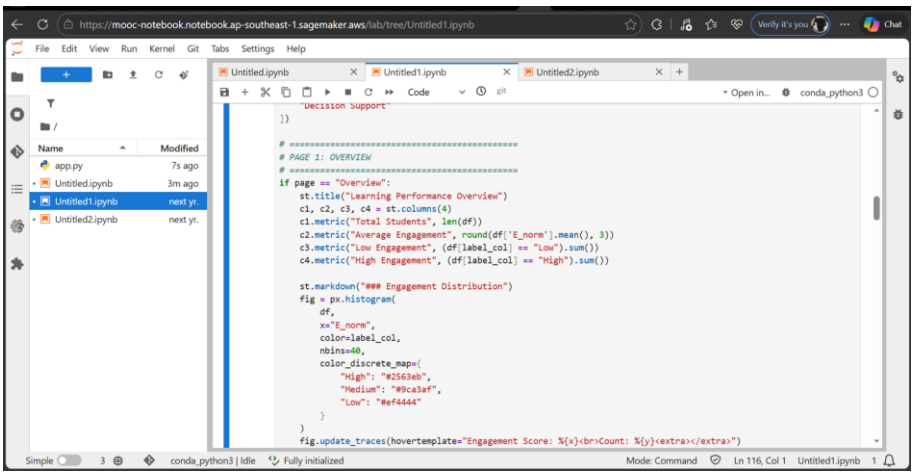

Hình 6.6 - CloudWatch để theo dõi log quá trình code trigger dữ liệu.

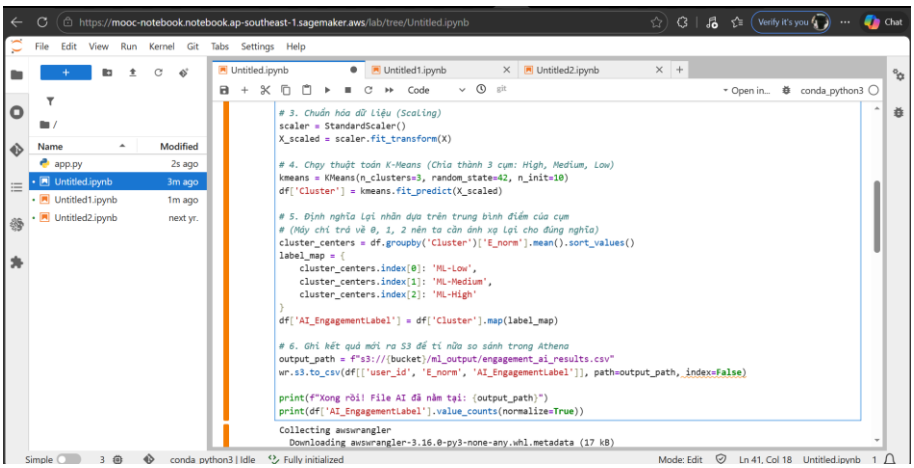

Hình 6.7 - Triển khai SageMaker Notebook chạy K-Means clustering và ánh xạ nhãn ML-Low, ML-Medium, ML-High)

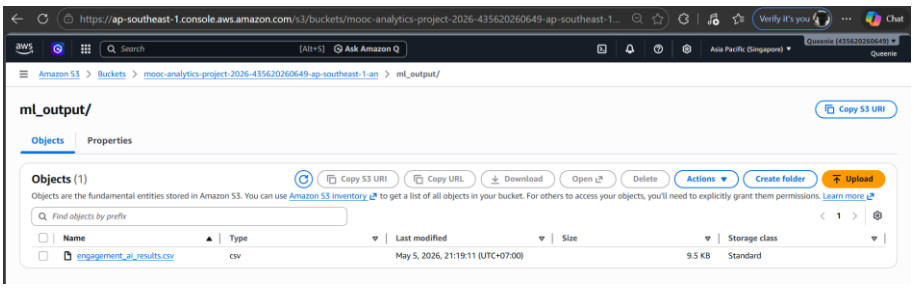

Hình 6.8 - Sau khi AI dán nhãn file được lưu lại vào S3.

(5) Dashboard BI – Tầng trực quan hóa và hỗ trợ ra quyết định (Data Visualization & Insights)

Hệ thống AI Phân tích Học tập

Vai trò:

Dashboard BI được xây dựng bằng **Streamlit** và triển khai qua **ngrok**, đóng vai trò là tầng cuối cùng của pipeline, nơi dữ liệu được chuyển hóa thành tri thức phục vụ ra quyết định.

Chức năng:

- Hiển thị tổng quan quản trị: số lượng học viên, điểm tương tác trung bình, tỷ lệ nhóm Low/High.

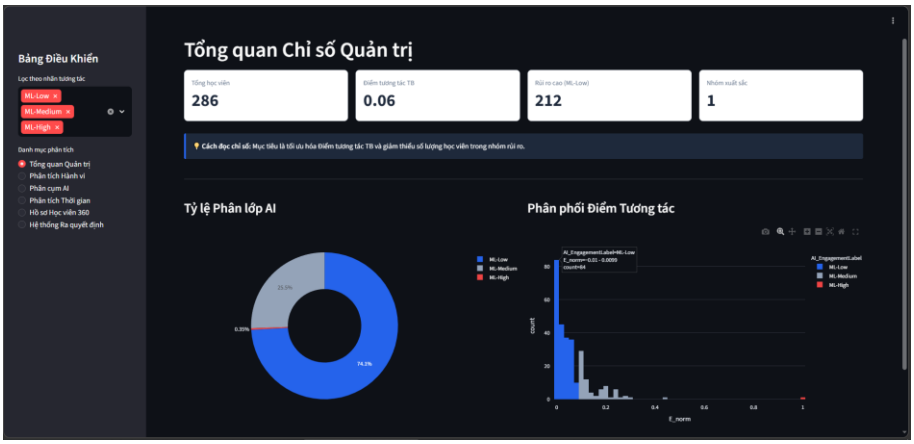

Hình 6.9 - Dashboard xây dựng bằng SageMaker Notebook kết hợp Ngrok 1.1

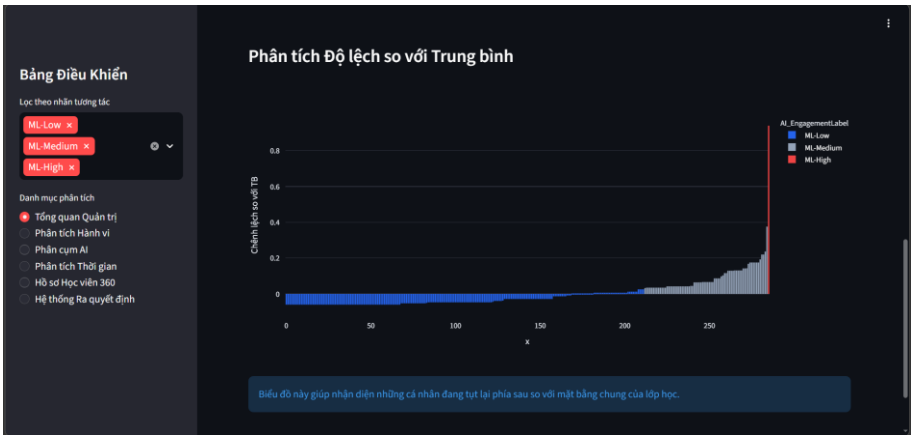

Hình 6.10 - Dashboard xây dựng bằng SageMaker Notebook kết hợp Ngrok 1.2

- Phân tích hành vi: biểu đồ phân phối video_views, assignment_score, login_freq.

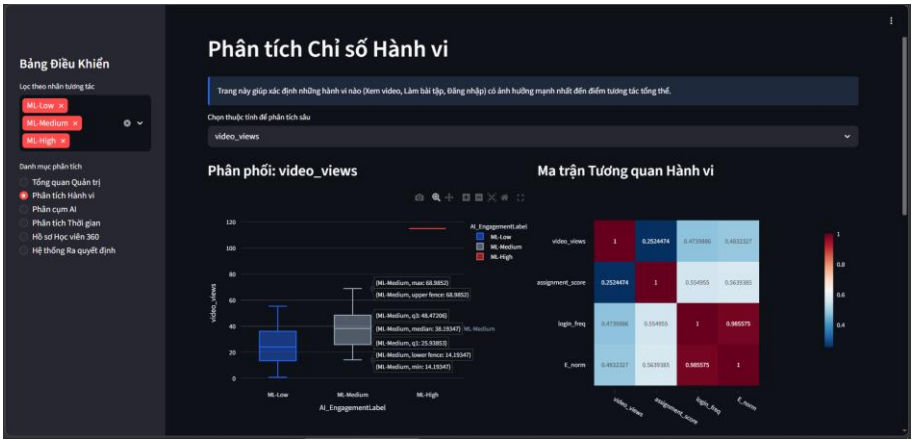

Hình 6.11 - Dashboard trang phân tích hành vi 1

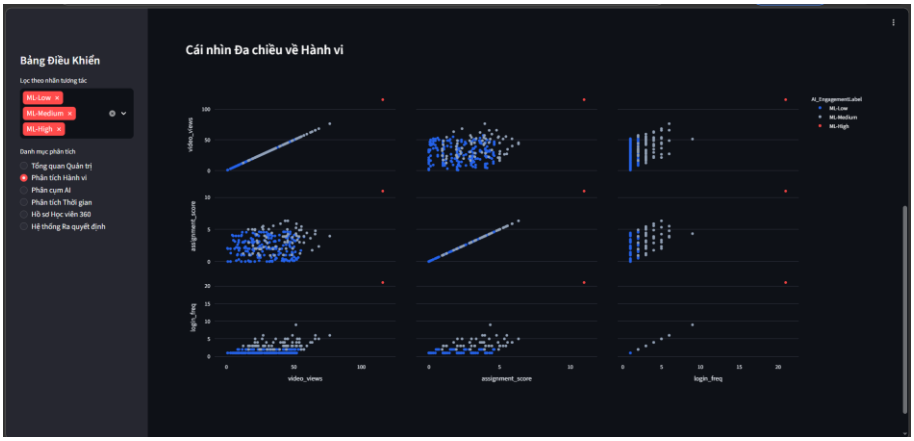

Hình 6.12 - Dashboard trang phân tích hành vi 2

- Phân cụm AI: hiển thị đặc điểm tiêu biểu của từng cụm học viên.

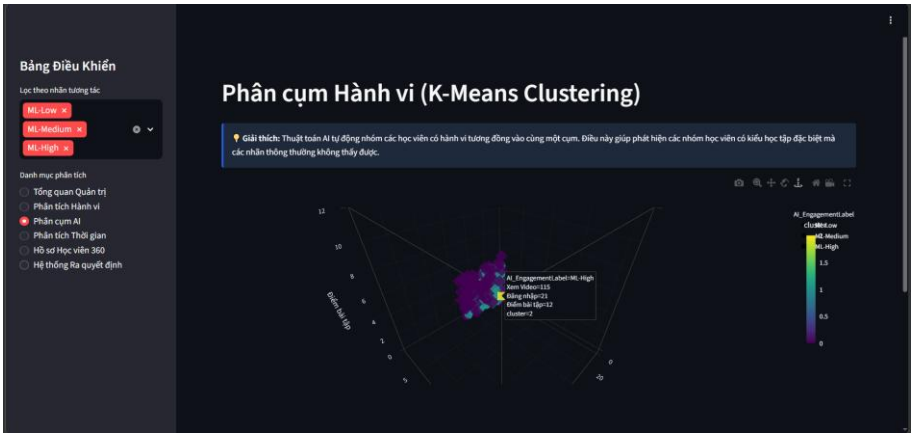

Hình 6.13 - Dashboard trang phân tích hành vi 3

- Hồ sơ học viên 360: so sánh chỉ số cá nhân với trung bình..

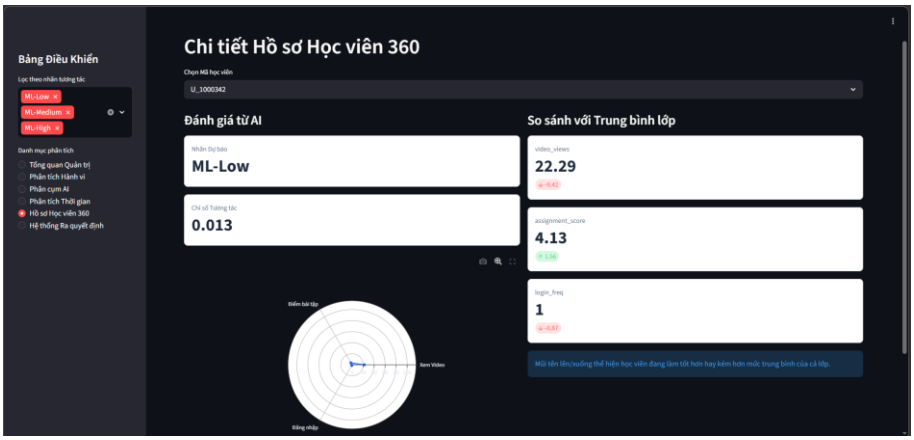

Hình 6.14 - Dashboard chi tiết hồ sơ tương tác của học viên.

- Phân tích xu hướng theo thời gian

Hình 6.15 - Dashboard phân tích xu hướng hành vi theo thời gian 1

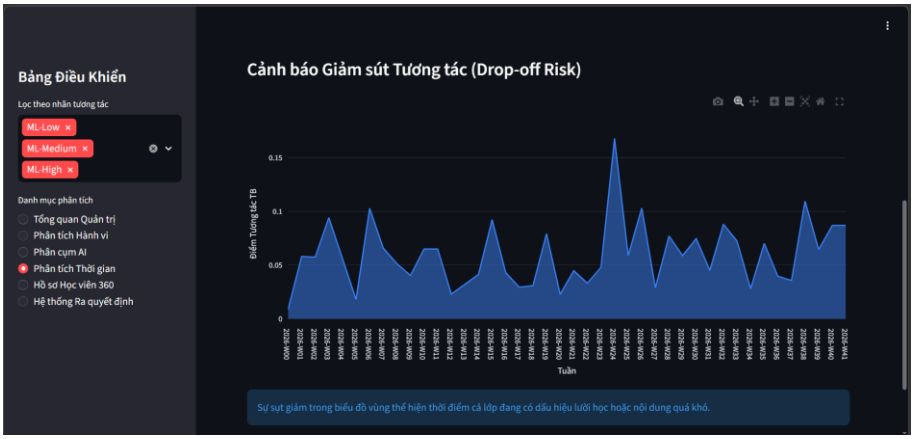

Hình 6.16 - Dashboard phân tích xu hướng hành vi theo thời gian 2

- Hệ thống ra quyết định: đề xuất hành động tự động cho nhóm học viên rủi ro cao.

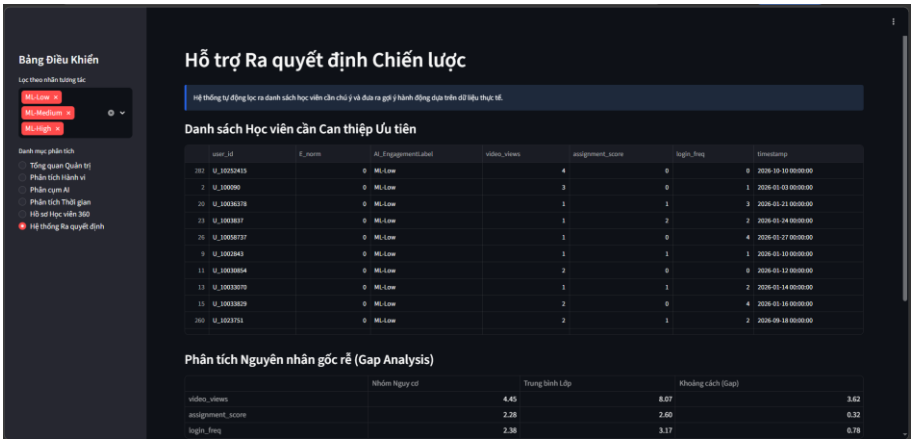

Hình 6.16 - Dashboard hỗ trợ ra quyết định 1

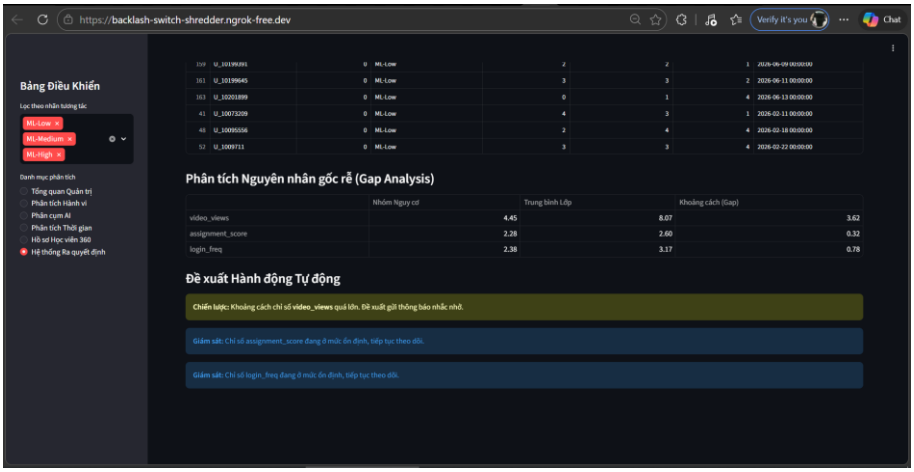

Hình 6.17 - Dashboard hỗ trợ ra quyết định 2

Lý do lựa chọn:

- Streamlit cho phép xây dựng giao diện phân tích nhanh, trực quan, dễ triển khai.
- Ngrok hỗ trợ truy cập từ xa, phù hợp cho demo và thử nghiệm nghiên cứu.

Ý nghĩa với đề tài:

Dashboard BI là cầu nối giữa kết quả phân tích và hành động thực tiễn. Nó giúp giảng viên và quản trị viên hiểu rõ hơn về hành vi học tập, từ đó đưa ra chiến lược giảng dạy phù hợp.

6.3 Đánh giá học thuật và ý nghĩa hệ thống

Kiến trúc **AWS Data Engineering Pipeline** không chỉ mang tính kỹ thuật mà còn có giá trị học thuật sâu sắc trong lĩnh vực **khai phá dữ liệu giáo dục**.

- **Tính tự động hóa:** quy trình xử lý dữ liệu được kích hoạt hoàn toàn tự động từ ingest đến visualization.
- **Tính khách quan:** gán nhãn bằng AI giúp loại bỏ sai lệch chủ quan trong đánh giá hành vi học tập.
- **Tính mở rộng:** kiến trúc AWS cho phép xử lý dữ liệu hàng triệu bản ghi mà không cần thay đổi cấu trúc hệ thống.
- **Tính minh bạch:** mọi kết quả đều được lưu trữ và truy vấn qua Athena, đảm bảo khả năng kiểm chứng.
- **Tính ứng dụng:** Dashboard BI cung cấp công cụ phân tích trực quan, giúp giảng viên và quản trị viên đưa ra quyết định dựa trên dữ

Chương 7: Kịch bản thực nghiệm

7.1 Giới thiệu bài toán

Sự phát triển của các nền tảng học trực tuyến mở đại trà (MOOC) mang lại cơ hội tiếp cận giáo dục quy mô lớn nhưng đồng thời đối mặt với thách thức lớn: tỷ lệ bỏ học (dropout rate) cao do thiếu vắng sự tương tác và giám sát trực tiếp. Để giải quyết vấn đề này, việc xây dựng một hệ thống cảnh báo sớm dựa trên dữ liệu là vô cùng cấp thiết.

Bài toán cốt lõi trong khai phá dữ liệu giáo dục (Educational Data Mining - EDM) là việc định nghĩa và đo lường mức độ tương tác (engagement) của sinh viên thường mang tính chủ quan và tĩnh. Đề tài này giải quyết bài toán đó bằng cách đề xuất một kiến trúc **Hybrid Machine Learning**. Thay vì dựa vào các ngưỡng điểm cố định, hệ thống khai thác chuỗi log thời gian thực, sử dung phương pháp định lượng để khám phá sự phân bố dự liệu của các mẫu hành vi tự nhiên (tạo Ground Truth), sau đó sử dụng các mô hình học có giám sát tiến tiến để phân lớp và dự báo sớm nguy cơ mất động lực học tập của sinh viên.

7.2. Phạm vi và mục tiêu nghiên cứu

7.2.1 Phạm vi nghiên cứu:

- Dữ liệu: Hệ sinh thái MOOCCubeX, bao gồm 5 nguồn dữ liệu dị thể (user, user-video, user-problem, comment, reply). Dữ liệu được tinh gọn thông qua quá trình tiền xử lý, tập trung phân tích tập mẫu đại diện khoảng 130.000 sinh viên.
- Mô hình: Các thuật toán học máy cổ điển và Ensemble Learning (Logistic Regression, Linear SVC, Decision Tree, Random Forest, XGBoost).

7.2.2 Mục tiêu nghiên cứu:

- Xây dựng luồng dữ liệu (Data Pipeline) tự động để làm phẳng (flattening) cấu trúc JSON đa cấp và hợp nhất dữ liệu đa nguồn.
- Xây dựng nhãn mức độ tương tác từ dữ liệu không có label.
- Trích xuất đặc trưng từ hành vi giai đoạn đầu.
- Huấn luyện và so sánh hiệu suất của 4 mô hình học có giám sát, xử lý triệt để bài toán mất cân bằng lớp (class imbalance) bằng kỹ thuật SMOTE.
- Trích xuất Feature Importance để xây dựng Dashboard cảnh báo sớm.

7.3. Mục tiêu thực nghiệm

- **Đánh giá khả năng dự báo chuỗi thời gian:** Xác định mô hình học có giám sát nào tối ưu nhất trong việc xử lý dữ liệu log hành vi tuần tự để dự báo nhãn tương tác.
- **Đánh giá hiệu quả của kỹ thuật cân bằng dữ liệu:** So sánh hiệu suất mô hình (đặc biệt là Recall của lớp "Low Engagement") trước và sau khi áp dụng SMOTE trên tập dữ liệu có phân bổ nhãn 1 : 1 : 1.
- Xây dựng pipeline hoàn chỉnh từ dữ liệu thô đến mô hình dự đoán, sao cho:
    1. Đạt độ chính xác dự đoán khoảng **0.6 +**
    2. Xác định các đặc trưng ảnh hưởng đến engagement
    3. Đảm bảo mô hình có khả năng giải thích

7.4. Môi trường thực nghiệm

Platform: Google Colab / Kaggle

Ngôn ngữ: Python 3.14

Thư viện chính:

- pandas: Xử lý dữ liệu
- numpy: Tính toán ma trận
- matplotlib & seaborn: Trực quan hóa
- scikit-learn: Machine Learning
- scipy: Phân tích thống kê

7.5. Đơn vị phân tích và phạm vi dự báo

Đơn vị phân tích (Unit of Analysis): Một bản ghi (record) trong tập dữ liệu huấn luyện đại diện cho hành vi của một sinh viên U_i trong một khoảng thời gian cụ thể (tuần W_t).

Phạm vi dự báo (Prediction Scope): Dự đoán mức độ tương khi học tập online trên nền tảng XuetangX dựa trên hành vi trong 28 ngày đầu.

7.6. CHIẾN LƯỢC GÁN NHÃN

Do không có ground truth, nhãn được xây dựng bằng phương pháp **Weighted Engagement Score (WES)**, quy trình bao gồm các bước:

1. Gom dữ liệu theo user_id và tính các đặc trưng toàn khóa như:

1. total_study_time
2. avg_score
3. accuracy_rate
4. attempts
5. total_forum_activities
6. …

2. Áp dụng: Laplace smoothing cho accuracy và chuẩn hóa bằng RobustScaler.

3. Tính trọng số bằng: Entropy Weight Method (EWM) sau đó tính điểm WES bằng công thức:

$$\mathbf{WES = \Sigma(feature \times weight)}$$

4. Mapping nhãn: Sử dụng phân vị:

- 0 – 33% → Low Engagement
- 33 – 67% → Medium Engagement
- 67 – 100% → High Engagement

7.7. QUY TRÌNH THỰC NGHIỆM

7.7.1. Giai đoạn 1: Định hình và trích xuất đặc trưng Time-Series

Hành vi học tập của người học mang tính tiến trình theo thời gian. Việc trích xuất đặc trưng trong giai đoạn đầu là nền tảng để xây dựng mô hình dự đoán sớm mức độ tương tác.

i. Xác định mốc thời gian học (Enrollment Time): Với mỗi học viên, xác định thời điểm bắt đầu học enroll_time. Trong trường hợp dữ liệu thiếu thông tin này, sử dụng thời điểm hành vi đầu tiên (min(action_time)) làm mốc thay thế nhằm đảm bảo tính nhất quán

ii. Chuẩn hóa trục thời gian (Time Alignment): Tính toán số ngày kể từ khi bắt đầu học:

$$\mathbf{days_since_enroll = action_time - enroll_time}$$

Việc chuẩn hóa này giúp đưa toàn bộ học viên về cùng một hệ quy chiếu thời gian.

iii. Cắt lát dữ liệu theo cửa sổ thời gian (Time Windowing): chỉ giữ lại các hành vi trong khoảng từ 0 đến 28 ngày đầu. Đây là bước quan trọng để mô phỏng bài toán early prediction, đảm bảo mô hình chỉ sử dụng thông tin sớm.

iv. Tổng hợp đặc trưng hành vi (Feature Aggregation): Thực hiện groupby(user_id) để chuyển dữ liệu từ dạng event-level sang user-level, tạo các đặc trưng:

a. Đặc trưng tĩnh: Giới tính, năm sinh, trường học, độ dài khóa học đã đăng ký.

b. Đặc trưng học tập:

- attempts_4w: tổng số lần làm bài
- is_correct_4w: tổng số lần làm đúng
- score_4w: điểm trung bình
- accuracy_rate_4w: tỷ lệ đúng

c. Đặc trưng tương tác:

- rep_counts: số phản hồi
- cmt_counts: số bình luận
- seq: mức độ hoạt động (proxy cho số lượng và mật độ sự kiện)

Các đặc trưng này phản ánh đầy đủ mức độ tham gia của học viên trong giai đoạn đầu của khóa học.

7.7.2. Giai đoạn 2: Khởi tạo nhãn chuẩn (Ground Truth) bằng Weighted Engagement Score (WES)

Do dữ liệu không có nhãn sẵn, đề tài xây dựng nhãn mức độ tương tác dựa trên phương pháp định lượng từ hành vi học tập toàn khóa học.

i. Xây dựng đặc trưng toàn khóa (Full-course Aggregation): Từ toàn bộ dữ liệu (không giới hạn 28 ngày), tính các đặc trưng tổng hợp:

- tổng thời gian học
- điểm trung bình
- tỷ lệ đúng
- số lần làm bài
- mức độ tương tác (forum activity)

ii. Chuẩn hóa dữ liệu (Robust Normalization): Áp dụng **RobustScaler** để đưa các đặc trưng về cùng thang đo và giảm ảnh hưởng của outlier.

iii. Xác định trọng số đặc trưng (Entropy Weight Method - EWM): Sử dụng phương pháp entropy để tính toán mức độ thông tin của từng đặc trưng, từ đó xác định trọng số khách quan cho mỗi biến.

iv. Tính Weighted Engagement Score (WES): Điểm engagement của mỗi học viên được tính bằng:

$$WES_i = \Sigma (x_{ij} \times w_j)$$

Trong đó:

- x_{ij}: giá trị đặc trưng đã chuẩn hóa
- w_j: trọng số của đặc trưng j

v. **Phân nhãn theo phân vị (Percentile-based Labeling):** Dựa trên phân bố của WES, chia thành 3 nhóm:

- Low Engagement (0 – 33%)
- Medium Engagement (33 – 67%)
- High Engagement (67 – 100%)

Phương pháp này đảm bảo việc gán nhãn mang tính dữ liệu-driven, không phụ thuộc giả định chủ quan.

7.7.3. Giai đoạn 3: Phân chia tập dữ liệu và Xử lý mất cân bằng (SMOTE)

Commented [t3]: bỏ SMOTE

Để đảm bảo mô hình học được phân phối dữ liệu thực tế và tránh sai lệch đánh giá, việc chia dữ liệu và xử lý mất cân bằng được thực hiện cẩn trọng.

i. Stratified Split (Phân chia có kiểm soát):Dữ liệu được chia thành:

Train: 80% | Validation: 10% | Test: 10%

Áp dụng **Stratified Sampling** để đảm bảo phân phối nhãn (Low, Medium, High) được giữ nguyên trong từng tập con, tránh hiện tượng lệch lớp.

ii. Xử lý mất cân bằng bằng SMOTENC: Do dữ liệu có sự chênh lệch giữa các lớp, đặc biệt là lớp Low và Medium, áp dụng: **SMOTENC (Synthetic Minority Over-sampling Technique for Categorical data)**

- Chỉ áp dụng trên **tập train.**
- Tạo thêm các mẫu nhân tạo cho các lớp thiểu số.
- Giữ nguyên tập validation và test để phản ánh đúng phân phối thực tế.

· Đảm bảo không xảy ra Data Leakage**:** Việc áp dụng SMOTE sau khi chia dữ liệu giúp tránh việc thông tin từ tập test "rò rỉ" vào quá trình huấn luyện, đảm bảo kết quả đánh giá phản ánh đúng hiệu năng khi triển khai thực tế.

7.7.4. Giai đoạn 4: Huấn luyện và tối ưu mô hình (Supervised Learning)

Mục tiêu của giai đoạn

Giai đoạn 4 được thiết kế nhằm huấn luyện các mô hình phân loại có giám sát để dự đoán mức độ tham gia học tập của sinh viên, với trọng tâm là phát hiện sớm nhóm Low_Engagement.

Trong bài toán này, độ chính xác tổng thể không phải là mục tiêu duy nhất. Mô hình cần đảm bảo:

- phát hiện được phần lớn sinh viên thuộc nhóm nguy cơ thấp;
- không tạo quá nhiều cảnh báo giả;
- có thể tổng quát hóa trên dữ liệu kiểm tra chưa từng dùng trong quá trình chọn mô hình.

Vì vậy, giai đoạn này sử dụng ba tập dữ liệu với vai trò khác nhau:

- **Train**: dùng để fit mô hình;
- **Validation**: dùng để chọn mô hình và tối ưu ngưỡng dự đoán;
- **Test**: chỉ dùng một lần ở cuối để đánh giá khách quan.

Trong giai đoạn này, dữ liệu đầu vào được chia làm 3 tập: Train (103.612 mẫu), Validation (12.952 mẫu) và Test (12.952 mẫu) với 7 đặc trưng cấu thành. Thực nghiệm đã tiến hành huấn luyện và so sánh hiệu năng trực tiếp của 5 thuật toán học máy: Logistic Regression, Linear SVC, Decision Tree, Random Forest và XGBoost.

Bảng 7.1 Bảng xếp hạng hiệu năng các thuật toán trên tập Validation:

Mô hình huấn luyện	**Accurac**	**Balanced Accurac**	**F1 Macro**	**F1 Weighte**	**Recall Low_Engageme**	**Precision Low_Engageme**	**F1 Low_Engageme**
Logistic Regression	0.6088	0.6060	0.5016	0.5033	**0.0117**	0.1645	0.0218
Linear SVC	0.6141	0.6113	0.4970	0.4987	0.0021	0.2000	0.0042
Decision Tree	0.6230	0.6204	0.5012	0.5029	0.0000	0.0000	0.0000
Random Fore	0.6228	0.6202	0.5017	0.5034	0.0009	0.2500	0.0019
XGBoost	0.6231	0.6205	0.5013	0.5030	0.0000	0.0000	0.0000

Lý do thuật toán Logistic Regression được lựa chọn triển khai:

- Trong hệ thống cảnh báo sớm, việc bỏ sót sinh viên có nguy cơ (False Negative) mang lại rủi ro cao hơn việc cảnh báo nhầm (False Positive). Do đó, tiêu chí tối thượng để chọn mô hình là chỉ số Recall của nhóm Low_Engagement.
- Dựa trên kết quả thực nghiệm, Logistic Regression là thuật toán chiến thắng do đạt chỉ số Recall_Low_Engagement cao nhất (0.0117). Mặc dù các thuật toán dạng cây (Decision Tree, Random Forest, XGBoost) đạt Accuracy và Balanced Accuracy nhỉnh hơn, nhưng khả năng nhận diện lớp Low_Engagement của chúng gần như bằng 0.
- Đánh giá trên tập Test độc lập cho thấy mô hình Logistic Regression đạt độ chính xác (Accuracy) 0.6106, Balanced Accuracy 0.6077 và duy trì Recall_Low_Engagement ở mức 0.0136. Mô hình được xuất ra dưới dạng tệp deployment_bundle.pkl để phục vụ triển khai.

7.7.5. Giai đoạn 5: Hệ thống tiêu chuẩn đánh giá (Evaluation Metrics)

a) Các độ đo hiệu suất mô hình (Khách quan)

Với bài toán Multi-class Classification và dữ liệu có sự chênh lệch nhãn gốc, độ chính xác tổng thể không phải là thước đo đáng tin cậy nhất. Kịch bản thực nghiệm sẽ sử dụng các độ đo sau trên tập test:

i. Confusion Matrix: Quan sát trực quan số lượng sinh viên bị dự đoán sai từ Low lên High.

ii. F1-Score:

- *Macro F1:* Trung bình cộng F1 của 3 nhãn, xử lý công bằng cả lớp Medium dù số lượng ít.
- *Weighted F1:* Trung bình F1 có tính đến trọng số tương đương với số lượng mẫu của từng nhãn.

iii. Precision - Recall: Đặc biệt chú trọng vào độ đo Recall của lớp Low. Trong ngữ cảnh giáo dục, ưu tiên cảnh báo nhầm một sinh viên bình thường - False Positive còn hơn là bỏ sót một sinh viên đang sắp bỏ học - False Negative.

iv. ROC-AUC (One-vs-Rest): Đo lường khả năng phân tách của mô hình giữa một lớp bất kỳ với các lớp còn lại. AUC > 0.85 được xem là mô hình có tính ứng dụng cao.

v. Feature Importance: Trích xuất từ cây quyết định của XGBoost/CatBoost để xác định Top 5 đặc trưng có tính quyết định nhất, làm cơ sở khoa học để thiết kế các chỉ số trên màn hình Dashboard cảnh báo.

b) Các tiêu chí đánh giá chất lượng dữ liệu (Data Quality Assessment)

Việc đánh giá mô hình không chỉ dừng ở đầu ra, mà còn phải đánh giá chất lượng dữ liệu đầu vào và xuyên suốt vòng đời dữ liệu, đảm bảo mô hình hoạt động trên nền tảng vững chắc theo các khía cạnh (dimensions) được định nghĩa trong Data Quality Framework.

Hệ thống đánh giá sẽ áp dụng phương pháp đo lường khách quan cho các khía cạnh sau:

- **Tính chính xác (Accuracy của dữ liệu):**
  - *Phương pháp khách quan:* Sử dụng phân tích thống kê (tỷ lệ lỗi, độ lệch chuẩn) để đảm bảo các giá trị hành vi (như attempts, score) phản ánh chính xác tương tác thực tế của sinh viên trên hệ thống.
  - So sánh với nguồn dữ liệu đáng tin cậy (ví dụ: đối chiếu log với cơ sở dữ liệu điểm số chính thức của trường) để xác minh tính chính xác.
- **Tính đầy đủ (Completeness):**
  - *Phương pháp khách quan:* Phân tích tỷ lệ dữ liệu thiếu (missing values) ở các trường quan trọng như enroll_time (như đã thấy trong log, hệ thống đã phải xử lý việc thiếu cột này).
  - Kiểm tra tính đầy đủ của thông tin hồ sơ sinh viên (age, gender, school) trước khi đưa vào huấn luyện mô hình.
- **Tính nhất quán (Consistency):**

- *Phương pháp khách quan:* Đảm bảo định dạng thời gian (create_time_x, create_time_y) đồng nhất trên toàn bộ tập dữ liệu được tổng hợp từ nhiều bảng phân tán khác nhau.
- Thực hiện phân tích độ tương quan để đảm bảo các thuộc tính dữ liệu không mâu thuẫn lẫn nhau.

- **Tính hợp lệ (Validity):**
  - *Phương pháp khách quan:* Kiểm tra các giá trị ngoại lệ (outliers) hoặc các giá trị không hợp lý (ví dụ: score lớn hơn 100%, hoặc thời gian học âm) bằng các phương pháp như IQR hoặc z-score.
- **Tính kịp thời (Timeliness):**
  - Trong bài toán Early Warning System, dữ liệu cần phải được cập nhật và xử lý với độ trễ thấp nhất có thể.
  - *Phương pháp khách quan:* Tính toán độ trễ từ khi sinh viên thực hiện hành vi đến khi hệ thống trích xuất Time-window features và đưa ra dự báo. Độ trễ cao có thể làm mất đi giá trị của việc "cảnh báo sớm".

Bằng việc kết hợp các chỉ số hiệu suất mô hình học máy với các tiêu chuẩn chất lượng dữ liệu doanh nghiệp, hệ thống không chỉ lựa chọn được mô hình phù hợp nhất mà còn đảm bảo độ tin cậy và khả năng triển khai thực tế của toàn bộ quy trình.

7.7.6. Giai đoạn 6: Khả năng giải thích mô hình: Model Interpretability

i. Mục tiêu của giai đoạn

Trong khai phá dữ liệu giáo dục (EDM), một mô hình có độ chính xác 99% nhưng hoạt động như một black-box sẽ bị loại bỏ khi triển khai. Giảng viên cần biết tại sao hệ thốn g đưa ra cảnh báo để có phương án sư phạm phù hợp. Ví dụ: Sinh viên rớt nhóm Low do không xem video hay do làm bài tập điểm kém? Giai đoạn này chuyển đổi kết quả toán học thành tri thức nghiệp vụ.

ii. Kỹ thuật thực hiện chi tiết

Áp dụng hai cấp độ giải thích từ tổng quát đến cục bộ:

a. Trích xuất độ quan trọng của đặc trưng (Global Interpretability - Feature Importance):

Kỹ thuật: Sử dụng chỉ số Gini Impurity giảm dần (Mean Decrease in Impurity) hoặc chỉ số Information Gain được cung cấp sẵn từ các mô hình dạng cây (Random Forest, XGBoost).

Thực thi: Độ quan trọng của đặc trưng (Feature Importance): Thông qua quá trình phân tích 6 đặc trưng đầu vào, hệ thống trích xuất Top 5 yếu tố có độ ảnh hưởng lớn

nhất đến mức độ tương tác, bao gồm theo thứ tự: accuracy_rate_4w, score_4w, num_courses, is_correct_4w và attempts_4w. Kết quả này được dùng làm tham số cứng để vẽ các biểu đồ cảnh báo trên màn hình Dashboard.

b. Giá trị SHAP (Local & Global Interpretability):

Dữ liệu SHAP được lấy mẫu ngẫu nhiên từ 1000 bản ghi trong tập Test.

Giải thích toàn cục (Global Interpretability): Hệ thống xuất biểu đồ, cung cấp cái nhìn tổng thể về cách các đặc trưng như tỷ lệ làm bài đúng hay số lượng khóa học điều phối xác suất phân lớp trên toàn bộ mẫu.

Giải thích cục bộ (Local Interpretability): Hệ thống thực hiện trích xuất báo cáo giải thích cho từng sinh viên cụ thể. Biểu đồ này phân tách chính xác các yếu tố làm tăng hoặc giảm điểm rủi ro của sinh viên, hỗ trợ thiết lập các hành động can thiệp học thuật kịp thời.

Chương 8: Kết luận và hướng phát triển

8.1 Kết luận

Trong bối cảnh giáo dục trực tuyến ngày càng phát triển, việc phân tích và dự đoán hành vi học tập của học viên đóng vai trò quan trọng trong việc nâng cao chất lượng đào tạo và giảm tỷ lệ bỏ học. Đề tài đã xây dựng thành công một hệ thống phân loại học viên dựa trên dữ liệu hành vi học tập từ bộ dữ liệu MOOCCubeX, thông qua việc kết hợp các phương pháp học máy và học sâu trong một pipeline xử lý dữ liệu hoàn chỉnh.

Một trong những đóng góp quan trọng của nghiên cứu là việc **xây dựng nhãn cho dữ liệu không có sẵn ground truth** thông qua phương pháp **Weighted Engagement Score (WES)**. Phương pháp này cho phép chuyển đổi dữ liệu hành vi rời rạc thành một chỉ số định lượng phản ánh mức độ tham gia học tập của học viên, từ đó phân loại thành ba nhóm: Low, Medium và High Engagement. Việc sử dụng phân vị giúp đảm bảo tính linh hoạt và phù hợp với đặc điểm phân phối của dữ liệu thực tế.

Bên cạnh đó, đề tài đã triển khai một **pipeline xử lý dữ liệu hoàn chỉnh trên nền tảng AWS**, bao gồm các bước từ thu thập, tiền xử lý, gán nhãn, huấn luyện mô hình đến trực quan hóa kết quả. Hệ thống này không chỉ đảm bảo tính tự động hóa mà còn có khả năng mở rộng, phù hợp với các bài toán dữ liệu lớn trong thực tế.

Kết quả thực nghiệm cho thấy:

- Các mô hình học máy truyền thống như Logistic Regression, Random Forest, XGBoost đều đạt độ chính xác ở mức ~0.6.

- Trong đó, **Logistic Regression được lựa chọn** do có khả năng nhận diện tốt hơn nhóm học viên có nguy cơ thấp (Low Engagement), mặc dù độ chính xác tổng thể không cao nhất.

- Các mô hình dạng cây có hiệu suất tổng thể tốt hơn nhưng lại gặp hạn chế trong việc phát hiện lớp thiểu số.

Ngoài ra, đề tài cũng tích hợp các kỹ thuật như **SMOTE** để xử lý mất cân bằng dữ liệu và **SHAP** để giải thích mô hình, giúp tăng tính minh bạch và khả năng ứng dụng thực tiễn của hệ thống.

8.2 Đánh giá các phương pháp

8.2.1. Weighted Engagement Score (WES)

Ưu điểm:

- Cho phép xây dựng nhãn từ dữ liệu không có sẵn label (giải quyết bài toán thực tế).
- Phản ánh mức độ tham gia một cách toàn diện nhờ kết hợp nhiều hành vi.
- Linh hoạt nhờ sử dụng phân vị thay vì ngưỡng cố định.

Nhược điểm:

- Phụ thuộc vào cách chọn đặc trưng và trọng số → có thể chưa phản ánh hoàn toàn bản chất hành vi.
- Mang tính tĩnh (aggregate), chưa tận dụng được yếu tố thời gian sâu.

8.2.2. Logistic Regression

Ưu điểm:

- Đơn giản, dễ triển khai, tốc độ nhanh.
- Dễ giải thích (interpretability cao).
- Hoạt động ổn định trên dữ liệu đã chuẩn hóa.

Nhược điểm:

- Giả định quan hệ tuyến tính → khó học được pattern phức tạp.
- Hiệu suất tổng thể không cao so với mô hình nâng cao.

8.2.3. Random Forest

Ưu điểm:

- Giảm overfitting nhờ ensemble.

- Xử lý tốt dữ liệu nhiễu.
- Cung cấp Feature Importance.

Nhược điểm:

- Mô hình cồng kềnh, tốn tài nguyên.
- Hiệu quả thấp với dữ liệu mất cân bằng nếu không xử lý thêm.

8.2.4. XGBoost

Ưu điểm:

- Hiệu năng cao, tối ưu tốt trên dữ liệu lớn.
- Có khả năng xử lý mất cân bằng (scale_pos_weight).
- Học được quan hệ phi tuyến mạnh.

Nhược điểm:

- Cần tuning nhiều siêu tham số.
- Khó giải thích hơn so với mô hình đơn giản.

8.2.5. CatBoost

Ưu điểm:

- Xử lý trực tiếp biến categorical.
- Tự động xử lý imbalance.
- Hiệu quả cao với dữ liệu thực tế.

Nhược điểm:

- Thời gian huấn luyện lâu.

- Phụ thuộc tài nguyên (GPU để tối ưu).

8.2.6. LSTM (Deep Learning)

Ưu điểm:

- Nắm bắt được tính chuỗi thời gian của hành vi học tập.
- Phù hợp cho bài toán dự báo sớm (early prediction).

Nhược điểm:

- Yêu cầu dữ liệu lớn và tài nguyên tính toán cao.
- Khó triển khai thực tế và khó giải thích.

8.2.7. K-Means Clustering

Ưu điểm:

- Gán nhãn khách quan (data-driven).
- Đơn giản, dễ triển khai.

Nhược điểm:

- Phụ thuộc vào số cụm K.
- Nhạy cảm với dữ liệu nhiễu và scale.

8.3 Hướng phát triển tiềm năng

Mặc dù đề tài đã đạt được những kết quả nhất định, vẫn còn nhiều hướng phát triển có thể mở rộng trong tương lai:

8.3.1. Cải tiến phương pháp gán nhãn

- Kết hợp **WES với K-Means hoặc Deep Clustering** để tạo nhãn chính xác hơn.
- Áp dụng các phương pháp học bán giám sát (Semi-supervised Learning).

8.3.2. Khai thác dữ liệu chuỗi sâu hơn

- Sử dụng các mô hình nâng cao như:
  - LSTM nâng cao
  - Transformer (Attention-based models)
- Phân tích hành vi theo timeline chi tiết thay vì aggregate.

8.3.3. Cải thiện khả năng dự báo sớm

- Giảm cửa sổ thời gian từ 28 ngày xuống 7–14 ngày.
- Xây dựng mô hình real-time prediction.

8.3.4. Tối ưu mô hình

- Áp dụng AutoML (Optuna, Bayesian Optimization).
- Ensemble nhiều mô hình để tăng hiệu suất.

8.3.5. Mở rộng hệ thống thực tế

- Tích hợp trực tiếp vào hệ thống LMS (Learning Management System).
- Xây dựng hệ thống **Early Warning System**:
  - Cảnh báo sinh viên có nguy cơ bỏ học
  - Đề xuất hành động can thiệp

8.3.6. Mở rộng dữ liệu

Kết hợp thêm:

- Dữ liệu clickstream
- Dữ liệu cảm xúc (NLP từ comment)

- Dữ liệu điểm danh, thi cử